

PRACA DYPLOMOWA MAGISTERSKA

Architektura mikroservisów i rozwiązania chmurowe w ekosystemie .NET

*Microservices Architecture and Cloud Solutions in the
.NET Ecosystem*

Mariusz Trzeciak

Nr albumu: 133583

Kierunek: Informatyka

Forma studiów: stacjonarne

Poziom studiów: II

Promotor pracy:

dr inż. Bartosz Kowalczyk

Praca przyjęta dnia:

Podpis promotora:

Częstochowa, 2026

*Niniejszym chciałbym serdecznie podziękować
Promotorowi, dr inż. Bartoszowi Kowalczykowi,
za cenne wskazówki i cierpliwość
w trakcie realizacji niniejszej pracy.*

Spis treści

1	Wstęp	3
1.1	Cel pracy	4
1.2	Zakres pracy	4
2	Wprowadzenie do architektury mikroserwisów w ekosystemie .NET	5
2.1	Definicja i charakterystyka architektury mikroserwisowej	5
2.2	Porównanie z architekturą monolityczną	6
2.3	Ekosystem .NET w kontekście mikroserwisów	7
3	Mechanizmy komunikacji w architekturze mikroserwisowej	9
3.1	Komunikacja asynchroniczna	9
3.2	Komunikacja synchroniczna	10
3.3	gRPC – architektura i implementacja	11
4	gRPC-Web i komunikacja frontend-backend	13
4.1	Ograniczenia natywnego gRPC w przeglądarkach	13
4.2	Architektura gRPC-Web	15
4.3	Implementacja we frameworku Angular	15
5	Wzorce projektowe i architektoniczne	17
5.1	Wzorzec Cache-Aside	17
5.2	Rola serwera pośredniczącego i mechanizmy odpornościowe	18
6	Zrealizowany system i jego wdrożenie	19
6.1	Architektura badanego systemu testowego	19
6.2	Wdrożenie i eksploatacja w środowisku chmurowym	21
6.3	Obserwowalność i śledzenie rozproszone	22
7	Metodologia badań i projekt eksperymentu	25
7.1	Cele i hipotezy badawcze	25
7.2	Adaptacja systemu na potrzeby eksperymentu	26
7.3	Metodyka pomiaru	28
7.4	Scenariusze i macierz badawcza	30
7.5	Środowisko testowe	32

7.6	Metryki i sposób agregacji wyników	34
8	Porównawcza analiza wydajności gRPC vs REST	37
8.1	Wolumen przesyłanych danych	37
8.2	Model liczby wymian pakietów	39
8.3	Analiza narzutu protokołu (Echo)	40
8.4	Analiza wydajności odczytu (Products)	42
8.5	Analiza wydajności zapisu (Orders)	44
8.6	Rozdzielenie wpływu serializacji od wpływu wersji protokołu HTTP .	46
8.7	Skalowanie z liczbą klientów i granica stanowiska pomiarowego . . .	47
8.8	Powtarzalność pomiarów i przedziały ufności	48
8.9	Weryfikacja hipotez badawczych	50
	Podsumowanie	53
	Bibliografia	57
	Spis rysunków	60
	Spis tabel	62
	Listing	63
	Streszczenie	64
	Summary	66
	Słowa kluczowe	68

Rozdział 1

Wstęp

Współczesne aplikacje internetowe coraz częściej funkcjonują jako systemy rozproszone, w których poszczególne funkcjonalności są realizowane przez niezależne usługi. Jednym z podejść do budowy takich systemów jest architektura mikroserwisowa, pozwalająca na podział aplikacji na mniejsze, niezależne komponenty. Wraz z takim podziałem pojawia się potrzeba sprawnej wymiany danych pomiędzy usługami oraz pomiędzy warstwą backendową a aplikacją kliencką.

W komunikacji z aplikacjami internetowymi szeroko stosowanym rozwiązaniem jest styl architektoniczny REST, którego założenia zostały opisane przez Roya Fieldinga [12]. W praktycznych zastosowaniach dane są często przesyłane w formacie JSON. Alternatywę stanowi gRPC, wykorzystujące binarny format Protocol Buffers oraz protokół HTTP/2 [15]. Rozwiązanie to zostało zaprojektowane z myślą o wydajnej komunikacji pomiędzy usługami, a badania porównawcze wskazują na możliwe korzyści związane między innymi z rozmiarem przesyłanych danych i czasem odpowiedzi [1].

Charakter komunikacji w przeglądarce internetowej powoduje jednak, że natywne gRPC nie może być wykorzystywane w niej w taki sam sposób jak w środowisku serwerowym. Rozwiązaniem tego problemu jest gRPC-Web, umożliwiające wykorzystanie mechanizmów gRPC w aplikacjach działających w przeglądarce [17]. Może ono być obsługiwane między innymi z wykorzystaniem Envoy Proxy [18] lub bezpośrednio przez serwer aplikacyjny, na przykład w środowisku ASP.NET Core [20]. Różne sposoby realizacji tej komunikacji wprowadzają odmienne charakterystyki techniczne, których wpływ na wydajność nie jest oczywisty.

W praktycznym systemie wynik pomiaru zależy również od warunków, w jakich wykonywane są zapytania. Znaczenie może mieć między innymi rozmiar przesyłanych danych, liczba równoczesnych klientów, sposób obsługi pamięci podręcznej oraz konieczność wykonania operacji na bazie danych. Z tego względu porównanie samych mechanizmów serializacji lub pojedynczych zapytań nie pozwala w pełni ocenić zachowania poszczególnych rozwiązań w warunkach zwiększonego obciążenia.

1.1 Cel pracy

Głównym celem pracy jest zaprojektowanie, implementacja oraz eksperymentalna walidacja systemu mikroservisowego w ekosystemie .NET 10, umożliwiającego porównawczą analizę wydajności protokołów komunikacji na granicy pomiędzy aplikacją przeglądarkową a warstwą usług.

W pracy postawiono następującą tezę: zastosowanie gRPC-Web w komunikacji przeglądarki z warstwą usług pozwala uzyskać lepszą wydajność niż klasyczny REST oparty na JSON, jednak przewaga ta nie jest uniwersalna i zależy od charakterystyki obciążenia, w szczególności od rozmiaru przesyłanych danych oraz poziomu współbieżności.

1.2 Zakres pracy

W rozdziale 2 przedstawiono fundamenty architektury mikroservisowej, porównanie z modelem monolitycznym oraz specyfikę ekosystemu .NET. Rozdział 3 omawia mechanizmy komunikacji synchronicznej i asynchronicznej wraz z architekturą frameworka gRPC. W rozdziale 4 scharakteryzowano ograniczenia natywnego gRPC w przeglądarkach, architekturę protokołu gRPC-Web oraz jego implementację we frameworku Angular. Rozdział 5 prezentuje wzorce architektoniczne zastosowane w systemie, w tym Cache-Aside, rolę serwera pośredniczącego oraz mechanizmy odpornościowe bazy danych. Rozdział 6 opisuje architekturę badanego systemu testowego, proces wdrożenia w środowisku chmurowym oraz warstwę obserwowalności. W rozdziale 7 sformułowano hipotezy badawcze, projekt aplikacji testowej, procedury pomiarowe oraz macierz scenariuszy badawczych. Rozdział 8 zawiera porównawczą analizę wydajności protokołów gRPC-Web i REST oraz weryfikację hipotez. Pracę zamyka podsumowanie zestawiające osiągnięte rezultaty, wnioski inżynierskie oraz kierunki dalszego rozwoju zrealizowanej platformy.

Rozdział 2

Wprowadzenie do architektury mikroserwisów w ekosystemie .NET

Niniejszy rozdział stanowi wprowadzenie do tematyki architektury mikroserwisów w kontekście nowoczesnego wytwarzania oprogramowania, z uwzględnieniem ekosystemu platformy .NET. Przedstawiono w nim podstawowe cechy architektury monolitycznej i mikroserwisowej, ich najważniejsze zalety i ograniczenia oraz kluczowe pojęcia i zasady projektowe związane z budową systemów mikroserwisowych.

2.1 Definicja i charakterystyka architektury mikroserwisowej

Architektura mikroserwisowa (ang. *microservices architecture*) polega na budowie systemu informatycznego jako zbioru niewielkich, autonomicznych usług realizujących ściśle określone funkcje biznesowe. W ujęciu Fowlera i Lewisa mikroserwisy stanowią niezależnie wdrażalne jednostki, uruchamiane w odrębnych procesach i komunikujące się za pomocą lekkich mechanizmów sieciowych [3]. Organizacja usług wokół zdolności biznesowych (ang. *business capabilities*) sprawia, że ich granice wyznacza zakres odpowiedzialności dziedzinowej, a nie podział na warstwy techniczne. Umożliwia to niezależne skalowanie, wdrażanie oraz modyfikowanie poszczególnych komponentów.

Nadrzędną cechą definiującą mikroserwis jest jego *niezależna wdrażalność* (ang. *independent deployability*), czyli możliwość wdrożenia pojedynczej usługi na środowisko produkcyjne bez konieczności jednoczesnej aktualizacji pozostałych elementów systemu [2]. Warunkiem koniecznym do jej osiągnięcia jest zachowanie luźnego sprzężenia, polegającego na minimalizacji wiedzy o wewnętrznej implementacji innych usług. Do najczęstszych przyczyn utraty tej autonomii należą współdzielone biblioteki zawierające logikę biznesową oraz bezpośredni dostęp do bazy danych innego mikroserwisu. Oba te przypadki wprowadzają ukryte

zależności, które w praktyce wymuszają zsynchronizowane wdrożenia.

Wymiana danych pomiędzy usługami odbywa się za pomocą lekkich protokołów komunikacyjnych, w tym HTTP oraz systemów kolejkowych. W odniesieniu do protokołu HTTP stopień dojrzałości implementacji stylu REST opisuje model dojrzałości Richardsona (ang. *Richardson Maturity Model*), klasyfikujący usługi według wykorzystania zasobów, standardowych metod HTTP oraz mechanizmów hipermedialnych (HATEOAS) [13]. Model ten nie definiuje formalnie architektury REST, lecz systematyzuje stopniowe wdrażanie jej kluczowych założeń.

Formalnych kryteriów dekompozycji systemu dostarcza metodyka projektowania dziedzinowego (ang. *Domain-Driven Design*, DDD). Jej kluczowym elementem jest *kontekst ograniczony* (ang. *Bounded Context*), rozumiany jako wyodrębniony obszar dziedziny, w którym obowiązuje jeden, spójny model pojęciowy [5]. Odwzorowanie granic kontekstu na pojedynczy mikroserwis zapewnia spójność odpowiedzialności biznesowej i stanowi fundament niezależnej wdrażalności. Zasadę tę zastosowano przy podziale platformy testowej zrealizowanej w ramach niniejszej pracy.

Projektowanie w ramach kontekstu ograniczonego wymaga również wypracowania *wspólnego języka* (ang. *Ubiquitous Language*), czyli słownika pojęć współdzielonego przez programistów i ekspertów dziedzinowych [5]. Stosowanie wspólnego języka eliminuje niejednoznaczności semantyczne (przykładowo pojęcie „klient” może mieć odmienne atrybuty w module sprzedaży i w module reklamacji) oraz zapobiega zniekształceniom modelu w kodzie źródłowym. Ponieważ metodyka DDD wyklucza istnienie jednego, uniwersalnego modelu dla całego przedsiębiorstwa, relacje i sposób przepływu danych pomiędzy odrębnymi kontekstami opisuje się za pomocą *mapowania kontekstów* (ang. *context mapping*). W miejscach, gdzie modele są wzajemnie rozbieżne, translację realizuje *warstwa ochronna* (ang. *anticorruption layer*), zabezpieczająca wewnętrzny model usługi przed przenikaniem struktur zewnętrznych.

2.2 Porównanie z architekturą monolityczną

Architektura monolityczna (ang. *monolithic architecture*) zakłada budowę systemu jako pojedynczej, spójnej jednostki wdrożeniowej. Wszystkie moduły funkcjonalne (warstwa prezentacji, logika biznesowa oraz dostęp do danych) współdzielą jedną bazę danych i funkcjonują w ramach pojedynczego procesu systemowego [2]. Skalowanie horyzontalne takiego rozwiązania wymaga replikacji całej aplikacji, niezależnie od tego, który komponent generuje wąskie gardło wydajnościowe. Wraz z rozrostem bazy kodu wydłużeniu ulega czas kompilacji, testowania i wdrożenia, a każda wprowadzana modyfikacja niesie ryzyko destabilizacji całego systemu.

Podejście mikroserwisowe eliminuje te ograniczenia poprzez dekompozycję

na niezależne usługi, co zmienia zarówno strukturę kodu, jak i model operacyjny. Zestawienie kluczowych różnic pomiędzy oboma paradygmatami przedstawia tabela 2.1.

Tabela 2.1: Porównanie architektury monolitycznej i mikroserwisowej; opracowanie własne na podstawie [2, 4]

Wymiar	Architektura monolityczna	Architektura mikroserwisowa
Jednostka wdrożeniowa	Jeden artefakt obejmujący cały system	Każda usługa może być wdrażana niezależnie
Skalowanie	Replikacja całej aplikacji	Skalowanie wybranych usług proporcjonalnie do zapotrzebowania
Warstwa danych	Wspólna baza danych dla modułów systemu	Baza danych przypisana do usługi
Spójność danych	Transakcje ACID w obrębie wspólnej bazy	Transakcje lokalne oraz mechanizmy zapewniania spójności między usługami
Izolacja awarii	Awaria modułu może wpłynąć na działanie całego procesu	Awaria pojedynczej usługi może być odizolowana od pozostałych, wymagane mechanizmy odpornościowe
Stos technologiczny	Zazwyczaj jednolity dla całego systemu	Może być dobierany niezależnie dla poszczególnych usług
Komunikacja	Wywołania wewnątrzprocesowe, bez narzutu komunikacji sieciowej	Wywołania sieciowe, obciążone dodatkowym opóźnieniem i ryzykiem błędów komunikacji
Złożoność operacyjna	Niższa: pojedynczy proces i prostszy potok CI/CD	Wyższa: wiele usług, orkiestracja, obserwowalność i telemetria

Przedstawione zestawienie wskazuje, że wybór architektury mikroserwisowej stanowi kompromis inżynierski, w którym zyski w zakresie skalowalności i niezależności wdrożeń okupione są znacznym wzrostem złożoności operacyjnej. Szczególne znaczenie ma przy tym wymiar komunikacji: zastąpienie szybkich wywołań wewnątrzprocesowych wywołaniami sieciowymi przenosi istotną część kosztu wykonania do warstwy transportowej. Właśnie ten narzut, jego optymalizacja oraz uwarunkowania na granicy klient-serwer stanowią główny przedmiot badań eksperymentalnych w dalszej części pracy.

2.3 Ekosystem .NET w kontekście mikroserwisów

Ewolucja platformy .NET od monolitycznego .NET Framework przez wieloplatformy .NET Core aż po wersje zunifikowane ugruntowała jej pozycję jako środowiska do tworzenia natywnych aplikacji chmurowych (ang. *cloud-native*) [6]. Wersja

.NET 10 (edycja LTS z listopada 2025 roku) [9], stanowiąca podstawę implementacyjną niniejszej pracy, rozwija kompilację statyczną *Native AOT* [10] oraz optymalizacje środowiska uruchomieniowego pod kątem wdrożeń kontenerowych.

Fundamentem mikroserwisów w ekosystemie .NET jest framework ASP.NET Core z serwerem Kestrel, interfejsem Minimal API oraz potokiem przetwarzania opartym na oprogramowaniu pośredniczącym (*middleware*) [6]. Wysokie pozycje Kestrela w testach TechEmpower (scenariusz *Fortunes*) [8] czynią go optymalnym wyborem dla usług o wysokich wymaganiach wydajnościowych. Ekosystem ten uzupełniają biblioteka `Grpc.AspNetCore` [20] (natywne wsparcie gRPC i gRPC-Web) oraz Entity Framework Core jako warstwa mapowania obiektowo-relacyjnego.

Rozdział 3

Mechanizmy komunikacji w architekturze mikroservisowej

Jak przedstawiono w rozdziale 2, architektura mikroservisowa zakłada podział systemu na niezależne usługi odpowiedzialne za określone obszary funkcjonalne. Każdy mikroservis funkcjonuje jako odrębny proces, co sprawia, że realizacja złożonych procesów biznesowych wymaga komunikacji pomiędzy poszczególnymi usługami. Wybór odpowiedniego mechanizmu wymiany danych ma istotne znaczenie dla wydajności, skalowalności i niezawodności całego systemu [4].

Mechanizmy komunikacji stosowane w architekturze mikroservisowej można podzielić ze względu na sposób wymiany danych na komunikację synchroniczną oraz asynchroniczną. W pierwszym przypadku usługa oczekuje na odpowiedź w ramach obsługi żądania, natomiast w drugim wymiana danych odbywa się niezależnie od bezpośredniej odpowiedzi odbiorcy, najczęściej za pośrednictwem brokera wiadomości. Oba podejścia znajdują zastosowanie w różnych scenariuszach i charakteryzują się odmiennymi właściwościami.

3.1 Komunikacja asynchroniczna

Komunikacja asynchroniczna zakłada rozdzielenie momentu wysłania wiadomości od jej przetworzenia przez odbiorcę. Nadawca nie musi oczekiwać na bezpośrednią odpowiedź usługi, a wiadomość może zostać przechowana przez pośredniczący broker i przetworzona w późniejszym czasie. Podejście to ogranicza bezpośrednie zależności pomiędzy usługami oraz umożliwia niezależne przetwarzanie wiadomości w warunkach zmiennego obciążenia. W ekosystemie .NET komunikacja asynchroniczna może być realizowana z wykorzystaniem brokerów wiadomości oraz bibliotek zapewniających abstrakcję nad ich obsługą.

3.2 Komunikacja synchroniczna

Komunikacja synchroniczna opiera się na modelu żądanie–odpowieź, w którym nadawca wysyła żądanie do odbiorcy i oczekuje na jego przetworzenie oraz zwrócenie odpowiedzi. Podejście to jest powszechnie stosowane zarówno w komunikacji pomiędzy aplikacjami internetowymi a usługami backendowymi, jak i pomiędzy mikroserwisami. W ekosystemie .NET komunikacja synchroniczna może być realizowana z wykorzystaniem różnych mechanizmów, w tym stylu REST oraz mechanizmów RPC.

REST API w ASP.NET Core

Representational State Transfer (REST) to styl architektoniczny sformalizowany przez Roya Fieldinga [12], definiujący zestaw reguł dla rozproszonych systemów hipermedialnych. W architekturze mikroserwisowej REST stanowi najpowszechniejszy mechanizm komunikacji synchronicznej ze względu na prostotę, uniwersalność oraz dojrzałość ekosystemu narzędziowego [2, 3]. Opiera się na wykorzystaniu metod protokołu HTTP (GET, POST, PUT, DELETE) do operacji na zasobach identyfikowanych przez URI, których reprezentację najczęściej stanowi format JSON.

Fielding zdefiniował sześć podstawowych ograniczeń stylu REST: architekturę klient–serwer, bezstanowość, buforowalność odpowiedzi, warstwowość systemu, opcjonalny kod na żądanie oraz jednolity interfejs [12]. W praktyce inżynierskiej kluczowy element jednolitego interfejsu, jakim jest sterowanie stanem aplikacji przez hipermedia (HATEOAS), bywa pomijany na rzecz prostszego modelu żądanie–odpowieź.

W środowisku .NET interfejsy REST API mogą być implementowane za pomocą platformy ASP.NET Core. Framework udostępnia między innymi model *Minimal API* [25], umożliwiający definiowanie punktów końcowych bez konieczności stosowania kontrolerów. Listing 3.1 przedstawia przykładową implementację asynchronicznego pobierania rekordu.

```
1 app.MapGet("/api/products/{id}", async (ProductDbContext db, string id)
   =>
2 {
3     var product = await db.Products
4         .AsNoTracking()
5         .FirstOrDefaultAsync(p => p.Id == id);
6
7     return product is null ? Results.NotFound() : Results.Ok(product);
8 });
```

Listing 3.1: Definicja punktu końcowego REST z wykorzystaniem Minimal API w .NET 10

Do głównych zalet stylu REST należą bezstanowość ułatwiająca skalowanie horyzontalne, natywna obsługa buforowania odpowiedzi w infrastrukturze sieciowej oraz czytelność formatu JSON. Do ograniczeń zalicza się narzut objętościowy danych tekstowych, brak ścisłego kontraktu binarnego oraz zjawisko nadmiernej komunikacji (ang. *chatty API*).

3.3 gRPC – architektura i implementacja

gRPC to framework komunikacji wykorzystujący protokół HTTP/2 oraz format serializacji Protocol Buffers, opracowany przez Google i udostępniony jako projekt open-source w 2015 roku [15]. W porównaniu do REST wykorzystuje binarną serializację danych oraz mechanizmy HTTP/2, w tym multipleksowanie wielu wywołań w ramach jednego połączenia TCP. Z tego względu jest często stosowany w komunikacji pomiędzy mikroservisami, gdzie istotne są wydajność i niskie opóźnienia.

Centralnym elementem gRPC jest kontrakt definiowany za pomocą języka Protocol Buffers, określający typy danych oraz operacje dostępne w usłudze [16]. Definicja zapisana w pliku `.proto` może zostać wykorzystana do automatycznej generacji kodu klienta i serwera. Przykładową definicję serwisu przedstawiono na listingu 3.2.

```
1 syntax = "proto3";
2
3 package product;
4
5 service ProductService {
6     rpc GetProduct (ProductRequest) returns (ProductResponse);
7     rpc StreamProducts (ProductRequest) returns (stream ProductResponse);
8 }
9
10 message ProductRequest {
11     string id = 1;
12 }
13
14 message ProductResponse {
15     string id = 1;
16     string name = 2;
17     double price = 3;
18 }
```

Listing 3.2: Definicja serwisu gRPC w formacie Protocol Buffers

W ekosystemie .NET obsługa gRPC jest dostępna za pośrednictwem pakietu `Grpc.AspNetCore`, który integruje framework z platformą ASP.NET Core. HTTP/2 zapewnia między innymi multipleksowanie wielu strumieni oraz kontrolę przepływu [21]. Kompresja nagłówków za pomocą algorytmu HPACK dodatkowo ogranicza

ilość przesyłanych danych [14]. W połączeniu z binarną serializacją Protocol Buffers pozwala to zmniejszyć rozmiar komunikatów w porównaniu z formatem JSON.

Rozdział 4

gRPC-Web i komunikacja frontend-backend

Mechanizm gRPC, omówiony szczegółowo w rozdziale 3, zapewnia wysoką wydajność oraz silne typowanie w komunikacji pomiędzy usługami backendowymi. Nativny protokół gRPC opiera się jednak na mechanizmach HTTP/2, których możliwości nie są w pełni dostępne z poziomu przeglądarek internetowych. Ograniczenie to wynika ze sposobu, w jaki przeglądarki udostępniają aplikacjom internetowym dostęp do warstwy sieciowej. Interfejsy programistyczne, takie jak *Fetch API* oraz *XMLHttpRequest*, nie zapewniają bezpośredniej kontroli nad ramkami HTTP/2 ani dostępu do nagłówków końcowych (ang. *trailing headers*), wykorzystywanych przez protokół gRPC.

W konsekwencji opracowano mechanizm gRPC-Web, umożliwiający aplikacjom uruchamianym w przeglądarce komunikację z usługami wykorzystującymi gRPC. W zależności od zastosowanej implementacji komunikacja ta może być realizowana za pośrednictwem serwera pośredniczącego lub bezpośrednio przez warstwę obsługującą gRPC-Web po stronie usługi. Niniejszy rozdział przedstawia ograniczenia natywnego gRPC w kontekście środowiska przeglądarkowego (sekcja 4.1), architekturę rozwiązania gRPC-Web wraz z rolą serwera pośredniczącego (sekcja 4.2) oraz sposób jego wykorzystania w aplikacji frontendowej (sekcja 4.3).

4.1 Ograniczenia natywnego gRPC w przeglądarkach

Protokół gRPC w swojej natywnej postaci wykorzystuje mechanizmy transportowe HTTP/2, w tym ramki typu `HEADERS` przesyłane po zakończeniu ciała odpowiedzi. Mechanizm ten, określany jako nagłówki końcowe (ang. *trailing headers*), służy do przekazywania metadanych dotyczących statusu wywołania procedury zdalnej po przesłaniu treści odpowiedzi. Zgodnie ze specyfikacją gRPC [15], status wywo-

łania jest przekazywany za pomocą metadanych końcowych, w szczególności nagłówek `grpc-status`, natomiast opis błędu może być przekazywany za pomocą nagłówka `grpc-message`.

Problem wynika z ograniczeń środowiska przeglądarkowego. Interfejs *Fetch API*, zdefiniowany przez specyfikację WHATWG, oraz interfejs *XMLHttpRequest* nie zapewniają aplikacji bezpośredniego dostępu do warstwy transportowej HTTP/2. W szczególności kod JavaScript wykonywany w przeglądarce nie może bezpośrednio odczytywać nagłówków końcowych odpowiedzi HTTP/2. Oznacza to, że mimo możliwości zestawienia połączenia HTTP/2 przeglądarka nie udostępnia aplikacji mechanizmu pozwalającego na bezpośrednią obsługę wszystkich elementów wymaganych przez natywny protokół gRPC.

Dodatkowym ograniczeniem jest sposób zarządzania połączeniami HTTP/2 przez przeglądarkę. Przeglądarka samodzielnie zarządza połączeniami oraz multipleksowaniem strumieni, podczas gdy natywny gRPC zakłada możliwość wykorzystania mechanizmów HTTP/2 w sposób niedostępny dla standardowych interfejsów JavaScript.

Wymienione ograniczenia sprawiają, że natywny gRPC nie może być wykorzystywany bezpośrednio przez kod wykonywany w przeglądarce w taki sam sposób jak w przypadku klientów backendowych. Rozwiązaniem tego problemu jest gRPC-Web, który dostosowuje sposób transportowania komunikatów gRPC do możliwości środowiska przeglądarkowego.

Tabela 4.1 przedstawia porównanie natywnego gRPC, gRPC-Web oraz REST w kontekście komunikacji pomiędzy przeglądarką a warstwą backendową.

Tabela 4.1: Porównanie natywnego gRPC, gRPC-Web oraz REST w kontekście komunikacji frontend-backend

Cecha	Natywny gRPC	gRPC-Web	REST
Wsparcie przeglądarek	Brak	Tak	Tak (natywne)
Wersja HTTP	HTTP/2	HTTP/1.1 lub HTTP/2	HTTP/1.1 lub HTTP/2
Typ strumieniowania	Dwukierunkowe	Tylko server-side	Brak (SSE opcjonalnie)
Kontrakt i typy	Obowiązkowy, Protobuf	Obowiązkowy, Protobuf	Opcjonalny (OpenAPI), JSON
Wymagane proxy	Nie	Opcjonalne	Nie
Złożoność konfiguracji	Niska	Średnia	Niska

Jak wynika z tabeli 4.1, gRPC-Web zachowuje istotne właściwości natywnego gRPC, w szczególności wykorzystanie kontraktu opartego na *Protocol Buffers* [16]. Jednocześnie dostosowuje sposób transportowania komunikatów do ograniczeń środowiska przeglądarkowego, między innymi poprzez rezygnację z dwukierunko-

wego strumieniowania. W ekosystemie .NET możliwe jest zastosowanie zarówno serwera pośredniczącego, takiego jak Envoy, jak i bezpośredniej obsługi gRPC-Web przez usługę ASP.NET Core.

4.2 Architektura gRPC-Web

Istotną różnicą pomiędzy natywnym gRPC a gRPC-Web jest sposób przekazywania informacji o statusie wywołania. W natywnym gRPC informacje te są przekazywane w nagłówkach końcowych HTTP/2. W gRPC-Web zostały one umieszczone w specjalnej ramce znajdującej się wewnątrz ciała odpowiedzi HTTP. Zgodnie ze specyfikacją gRPC-Web ramka końcowa jest poprzedzona bajtem flagi o wartości `0x80`, natomiast ramki zawierające właściwe komunikaty oznaczane są wartością `0x00` [19].

Takie rozwiązanie pozwala na przesyłanie komunikatów gRPC z wykorzystaniem mechanizmów dostępnych dla aplikacji przeglądarkowych. Warstwa gRPC-Web może być obsługiwana bezpośrednio przez serwer aplikacyjny albo przez dedykowany serwer pośredniczący. W niniejszej pracy wykorzystano oba warianty, co umożliwia ich późniejsze porównanie pod względem wydajności.

W wariancie wykorzystującym Envoy przeglądarka wysyła żądania gRPC-Web do serwera pośredniczącego. Envoy, wyposażony w filtr `grpc_web`, odpowiada za przekształcenie komunikacji pomiędzy formatem gRPC-Web używanym przez klienta a natywnym gRPC wykorzystywanym przez usługę backendową. W wariancie Direct dodatkowa warstwa proxy nie występuje, ponieważ obsługa gRPC-Web realizowana jest bezpośrednio przez aplikację ASP.NET Core.

4.3 Implementacja we frameworku Angular

Opisane warianty gRPC-Web wymagają klienta działającego w rzeczywistym środowisku przeglądarkowym. W niniejszej pracy rolę tę pełni aplikacja frontendowa wykorzystująca framework *Angular 20*. Aplikacja odpowiada zarówno za prezentację danych, jak i obsługę komunikacji z backendem. Jej architektura została przygotowana w taki sposób, aby umożliwić przełączanie pomiędzy badanymi wariantami komunikacji bez zmiany warstwy prezentacji.

Do obsługi gRPC-Web wykorzystano bibliotekę *Connect RPC* opracowaną przez firmę Buf [29]. Biblioteka udostępnia klienta gRPC-Web dla aplikacji wykorzystujących moduły ECMAScript oraz współpracuje z generowanym kodem TypeScript. W porównaniu z klasyczną biblioteką `grpc-web` rozwiązanie to lepiej integruje się z procesem budowania zastosowanym w badanej aplikacji.

Generowanie kodu i Connect RPC

Komunikacja wykorzystująca gRPC-Web została oparta na kontrakcie zdefiniowanym w języku Protocol Buffers. Na podstawie plików `.proto` generowany jest kod TypeScript wykorzystywany następnie przez aplikację Angular. W procesie tym wykorzystano kompilator Protocol Buffers [22] oraz wtyczki `protoc-gen-es` i `protoc-gen-connect-es`. Pierwsza z nich odpowiada za generowanie definicji komunikatów, natomiast druga za generowanie deskryptorów usług wykorzystywanych przez bibliotekę Connect RPC.

Listing 4.1 przedstawia konfigurację generowania kodu klienckiego.

```
1  # Instalacja bibliotek klienckich i wtyczek generatora
2
3
4  npm install @connectrpc/connect @connectrpc/connect-web
5
6  npm install --save-dev @bufbuild/protoc-gen-es \
7    @connectrpc/protoc-gen-connect-es
8
9  # Wywołanie generatora
10
11  grpc_tools_node_protoc \
12    --plugin=protoc-gen-es=node_modules/.bin/protoc-gen-es \
13    --es_out=src/generated-connect \
14    --plugin=protoc-gen-connect-es=node_modules/.bin/protoc-gen-connect-es \
15    --connect-es_out=src/generated-connect \
16    -I ../../protos \
17    ../../protos/product.proto ../../protos/order.proto
```

Listing 4.1: Generowanie kodu klienckiego dla Connect RPC

Wywołanie generatora zostało umieszczone w skrypcie npm, dzięki czemu proces generowania kodu może być wykonywany w sposób powtarzalny podczas budowania projektu. Podejście to zapewnia również spójność pomiędzy kontraktem zapisanym w plikach Protocol Buffers a kodem wykorzystywanym przez aplikację frontendową.

Rozdział 5

Wzorce projektowe i architektoniczne

Jak wykazano w rozdziale 2, architektura mikroserwisowa dekomponuje system informatyczny na zbiór autonomicznych usług, z których każda odpowiada za odrębną dziedzinę biznesową. Taka dekompozycja niesie ze sobą szereg wyzwań projektowych, takich jak organizacja ścieżek odczytu i zapisu, ograniczenie kosztu przetwarzania danych oraz zapewnienie odporności poszczególnych komponentów systemu. Odpowiednio dobrane wzorce projektowe i architektoniczne pozwalają uporządkować te mechanizmy oraz dostosować je do specyfiki projektowanego systemu.

Niniejszy rozdział przedstawia wzorce i mechanizmy zastosowane w implementowanym na potrzeby pracy systemie, które mają znaczenie dla jego architektury oraz przeprowadzonych badań wydajnościowych. Omówiono organizację pamięci podręcznej zgodnie ze wzorcem Cache-Aside (sekcja 5.1) oraz rolę serwera pośredniczącego Envoy Proxy i mechanizmu ponawiania operacji bazodanowych (sekcja 5.2). Przedstawione rozwiązania stanowią element infrastruktury wykorzystanej następnie podczas badań porównawczych opisanych w dalszej części pracy.

5.1 Wzorzec Cache-Aside

Wzorzec *Cache-Aside* polega na bezpośrednim zarządzaniu pamięcią podręczną przez warstwę aplikacji, która odpowiada za synchronizację pomiędzy magazynem podręcznym a głównym źródłem danych [26]. W trakcie operacji odczytu aplikacja weryfikuje dostępność żadanego zasobu w magazynie podręcznym na podstawie deterministycznie wygenerowanego klucza. W przypadku trafienia (ang. *cache hit*) dane są natychmiast zwracane z pamięci operacyjnej bez angażowania relacyjnej bazy danych. W sytuacji chybienia (ang. *cache miss*) aplikacja kieruje zapytanie do głównej bazy danych, po czym otrzymany wynik zapisuje w pamięci podręcznej z określonym czasem ważności (ang. *Time to Live*, TTL) i dopiero wtedy odsyła go do klienta, dzięki czemu kolejne odwołania do tego samego zasobu są już serwowane bezpośrednio z bufora.

Zastosowanie tego podejścia przynosi wymierne korzyści architektoniczne, ponieważ w pamięci podręcznej alokowane są wyłącznie dane rzeczywiście pożądane przez użytkowników, co zapobiega marnotrawieniu zasobów na rzadko odpytywane rekordy. Głównym wyzwaniem pozostaje kwestia unieważniania nieaktualnych wpisów (ang. *cache invalidation*), którą realizuje się zazwyczaj poprzez pasywne wygasanie czasowe TTL lub jawne usuwanie i aktualizowanie odpowiednich kluczy w momencie wykonywania operacji zapisu lub modyfikacji danych w głównym magazynie.

5.2 Rola serwera pośredniczącego i mechanizmy odpornościowe

W rozproszonych architekturach zorientowanych na usługi serwery pośredniczące (ang. *reverse proxy* lub *API Gateway*) pełnią kluczową rolę w zarządzaniu ruchem przychodzącym, agregacji żądań oraz translacji protokołów komunikacyjnych. Narzędzia takie jak Envoy Proxy, zaimplementowane w językach natywnych o wysokiej wydajności, są powszechnie stosowane do mostkowania ruchu pomiędzy różnymi standardami sieciowymi, np. do konwersji zapytań przeglądarkowych gRPC-Web na natywny protokół gRPC oparty o HTTP/2. Zastosowanie dedykowanego serwera pośredniczącego pozwala na odseparowanie zadań infrastrukturalnych od logiki biznesowej usług backendowych, jednak wprowadza dodatkowy przeskok sieciowy (ang. *network hop*) oraz potencjalny narzut związany z przetwarzaniem i buforowaniem ramek danych.

Niezależnie od warstwy routingu i pośrednictwa sieciowego, kluczowym aspektem projektowania systemów rozproszonych pozostaje odporność na awarie (ang. *resilience*). Zgodnie z praktykami inżynierii stabilności systemów [24], mechanizmy odpornościowe dzieli się na dwie główne kategorie: operujące na poziomie komunikacji sieciowej oraz na poziomie dostępu do trwałych magazynów danych.

W warstwie dostępu do baz danych powszechnie stosuje się strategie ponawiania operacji (ang. *retry patterns*) z wykładniczym wydłużaniem czasu oczekiwania (ang. *exponential backoff*) oraz losowym rozrzutem czasowym (ang. *jitter*) [27]. Mechanizmy te adresują problem błędów przemijających (ang. *transient faults*), takich jak chwilowe zerwanie połączenia TCP, limity puli połączeń czy przeciążenie serwera bazodanowego, umożliwiając automatyczne wznowienie przerwanej operacji bez propagacji błędu do użytkownika końcowego.

Rozdział 6

Zrealizowany system i jego wdrożenie

Niniejszy rozdział przedstawia system zrealizowany na potrzeby pracy. Omówiona zostaje architektura systemu wraz z kontraktami usług i topologią kontenerów, implementacja pamięci podręcznej istotna dla przyjętej metodyki pomiaru, a także model wdrożenia w środowisku chmurowym oraz warstwa obserwowalności.

6.1 Architektura badanego systemu testowego

Na potrzeby przeprowadzenia eksperymentów wydajnościowych zrealizowano autorski system e-commerce, którego model domenowy został zainspirowany referencyjną architekturą mikrousług firmy Microsoft (będącą następcą projektu *eShopOnContainers*) [7]. Implementacja została w pełni podporządkowana celom badawczym, skupiając się na precyzyjnym porównaniu wybranych protokołów i wariantów komunikacji sieciowej. Architektura systemu składa się z trzech głównych warstw: warstwy prezentacji w postaci aplikacji przeglądarkowej, warstwy usług biznesowych złożonej z mikroservisów opartych na platformie .NET 10 oraz warstwy infrastrukturalnej obejmującej relacyjne bazy danych, pamięć podręczną i komponenty obserwowalności.

Środowisko eksperymentalne zostało rozproszone pomiędzy dwie fizyczne maszyny: warstwa mikroservisów wraz z całą infrastrukturą pomocniczą została uruchomiona na zewnętrznym serwerze, natomiast aplikacja kliencka działała lokalnie, na stacji roboczej pełniącej rolę węzła pomiarowego.

Przyjęte podejście powinno zagwarantować, że pomiary odzwierciedlają kompletną, rzeczywistą ścieżkę przetwarzania danych, uwzględniając opóźnienia sieciowe, warstwę pośredniczącą, routing, a także procesy serializacji i deserializacji realizowane przez silnik JavaScript w przeglądarce internetowej.

Warstwa usług biznesowych

System realizuje podział na dwa mikroserwisy zgodnie z zasadą *Bounded Context* [5]:

- ▶ **ProductService** (kontekst: katalog produktów) – odpowiada za operacje odczytu katalogu, implementuje wzorzec Cache-Aside oraz punkt końcowy izolujący narzut protokołu. Dane przechowywane w dedykowanej bazie `eshop_products` obejmują 2000 produktów rozłożonych na dziesięć kategorii.
- ▶ **OrderService** (kontekst: proces zamówień) – odpowiada za tworzenie zamówień: waliduje żądanie, zapisuje encję zamówienia wraz z jego pozycjami. Dane przechowywane w dedykowanej bazie `eshop_orders`.

Każdy mikroserwis jest autonomiczną jednostką wdrożeniową z własnym obrazem kontenera, konfiguracją połączeń oraz migracjami bazy danych realizowanymi w podejściu Code-First.

Istotną cechą przyjętego projektu jest całkowity brak zależności pomiędzy obiema usługami: nie występują ani synchroniczne wywołania, ani wymiana komunikatów pomiędzy `ProductService` a `OrderService`. Decyzja ta wynika bezpośrednio z celu badawczego: przedmiotem pomiaru jest komunikacja na granicy klient–usługa, a nie orkiestracja procesu obejmującego wiele usług. Wprowadzenie zależności międzyusługowej wnosiłoby do pomiarów opóźnienie drugiej usługi, utrudniając izolację narzutu samego protokołu. Konsekwencją takiego podziału jest pełna niezależność wdrożeniowa obu komponentów oraz brak sprzężenia.

Podejście Contract-First

Kontrakty usług gRPC definiowane są w plikach Protocol Buffers, stanowiących jedyne źródło prawdy (ang. *single source of truth*) dla interfejsów systemowych. Na ich podstawie generowany jest kod zarówno po stronie serwera (C#, pakiet `Grpc.Tools`), jak i klienta (TypeScript, narzędzia `@bufbuild/protoc-gen-es` oraz `@connectrpc/protoc-gen-connect-es`). Podejście Contract-First zapewnia spójność typów na granicy systemu i przenosi wykrywanie niekompatybilnych zmian z czasu wykonania na etap kompilacji.

Topologia Docker Compose

Cały system uruchamiany jest za pomocą Docker Compose, orkiestrującego siedem kontenerów. Tabela 6.1 przedstawia limity zasobów przydzielone poszczególnym kontenerom w konfiguracji wdrożeniowej.

Tabela 6.1: Limity zasobów kontenerów w konfiguracji wdrożeniowej systemu autorskiego

Kontener	Obraz	Limit CPU	Limit RAM
product-service	obraz własny (.NET 10)	4,0	3 GB
order-service	obraz własny (.NET 10)	4,0	3 GB
envoy	envoyproxy/envoy:v1.29-latest	4,0	1 GB
postgres	postgres:17-alpine	4,0	4 GB
redis	redis:7.2-alpine	1,0	512 MB
prometheus	prom/prometheus:v2.51.2	1,0	512 MB
grafana	grafana/grafana:10.4.2	1,0	512 MB

6.2 Wdrożenie i eksploatacja w środowisku chmurowym

System testowy wdrożono w publicznej chmurze obliczeniowej, w modelu infrastruktury jako usługi (ang. *infrastructure as a service*). Niniejsza sekcja przedstawia przyjęty model wdrożenia wraz z jego uzasadnieniem, przebieg wdrożenia oraz warstwę obserwowalności. Rozstrzygnięcia omówione poniżej wynikają w znacznej mierze z wymagań eksperymentu.

Uzasadnienie przyjętego modelu wdrożenia

Wszystkie komponenty systemu uruchomiono jako kontenery na pojedynczej instancji maszyny wirtualnej, zarządzane narzędziem Docker Compose w konfiguracji przedstawionej w tabeli 6.1. Rozwiązanie alternatywne, to jest wdrożenie w klastrze zarządzanym platformą Kubernetes wraz z automatycznym skalowaniem poziomym odrzucono ze względu na wymagania pomiarowe.

Mechanizmy automatycznego skalowania oraz ponownego rozmieszczania kontenerów zmieniają liczbę i lokalizację instancji w czasie działania systemu. Topologia stała nie stanowi w tych warunkach uproszczenia, lecz warunek powtarzalności pomiaru. Przyjęty model nie jest zatem podyktowany wygodą, lecz celem badawczym: przedmiotem pomiaru jest narzut protokołu komunikacji, nie właściwości platformy orkiestracji.

Proces wdrożenia

System wdrożono na serwerze chmury Hetzner Cloud o ośmiu rdzeniach wirtualnych i 16 GB pamięci, z wykorzystaniem Docker Compose w konfiguracji wdrożeniowej. Proces wdrożenia obejmuje konfigurację serwera, weryfikację punktów końcowych gotowości każdego mikroservisu oraz wykonanie automatycznych migracji bazy danych przy starcie usług.

Graf zależności Docker Compose zapewnia prawidłową kolejność uruchamiania kontenerów. Mechanizm ten eliminuje błędy wynikające z przedwczesnych prób połączenia z niedostępnymi usługami. Podstawą kontroli stanu są punkty końcowe `/healthz/live` oraz `/healthz/ready`, udostępniane przez wbudowany w ASP.NET Core[6].

6.3 Obserwowalność i śledzenie rozproszone


System integruje dwa filary obserwowalności zgodnie ze standardem OpenTelemetry [11], obejmując: metryki eksportowane do Prometheusa przez dedykowany punkt końcowy (czas odpowiedzi, liczba aktywnych połączeń oraz parametry środowiska uruchomieniowego .NET), a także warstwę wizualizacji danych opartą na platformie Grafana z automatycznie wdrażaną konfiguracją źródeł oraz paneli analitycznych.

Pulpity Grafany wdrażane są wraz z całym stosem, w postaci definicji przechowywanych w repozytorium i wczytywanych przy starcie kontenera. Dzięki temu warstwa wizualizacji odtwarzana jest automatycznie na każdym środowisku, bez ręcznej konfiguracji. Pierwszy z pulpitów (rysunek 6.1) obejmuje charakterystykę warstwy HTTP obu mikroserwisów: liczbę żądań na sekundę oraz percentyle czasu obsługi żądania mierzone po stronie serwera. Drugi (rysunek 6.2) przedstawia rozbięcie liczby żądań na poszczególne trasy oraz metryki środowiska uruchomieniowego .NET: wolumen alokacji pamięci i częstość usuwania zbędnych obiektów z pamięci aplikacji.

Przedstawione przebiegi zarejestrowano w trakcie obciążeniowej weryfikacji stosu obserwowalności, nie zaś podczas przebiegu macierzy badawczej. Ilustrują one działanie warstwy monitorowania, a nie rezultaty eksperymentu. Warstwa obserwowalności pełniła w nim funkcję pomocniczą, nie pomiarową.



Rysunek 6.1: Pulpit Grafany – liczba żądań na sekundę oraz percentyle czasu obsługi żądania po stronie usług `ProductService` i `OrderService`



Rysunek 6.2: Pulpit Grafany – liczba żądań w podziale na trasy oraz metryki środowiska uruchomieniowego .NET: wolumen alokacji i częstość odśmiecania pamięci

Rozdział 7

Metodologia badań i projekt eksperymentu

Rozdziały 2–5 przedstawiły fundamenty architektury mikroserwisowej, mechanizmy komunikacji synchronicznej i asynchronicznej, specyfikę protokołu gRPC-Web oraz wzorce projektowe zastosowane w zrealizowanym systemie. Zgromadzona wiedza pozwala na sformułowanie hipotez badawczych dotyczących wydajności protokołów komunikacji w warunkach odpowiadających rzeczywistemu zastosowaniu, to jest w komunikacji przeglądarki internetowej z warstwą usług przez łącze rozległe.

Niniejszy rozdział opisuje metodologię przeprowadzonego eksperymentu: cele i hipotezy badawcze, projekt aplikacji testowej, metodykę pomiaru wraz z mechanizmami kontroli czynników zakłócających, macierz scenariuszy badawczych, środowisko testowe wraz z jego zmierzoną charakterystyką, przyjęte metryki, sposób agregacji wyników oraz kryterium rozstrzygalności zmierzonych różnic, a także ograniczenia metodologiczne.

7.1 Cele i hipotezy badawcze

Głównym celem badawczym pracy jest porównawcza analiza wydajności protokołów komunikacji dostępnych dla aplikacji przeglądarkowej współpracującej z mikroserwisami zrealizowanymi w ekosystemie .NET 10. Przedmiotem pomiaru są trzy warianty:

1. REST API – HTTP/1.1 z serializacją tekstową JSON,
2. gRPC-Web przez proxy Envoy – HTTP/1.1 po stronie przeglądarki, translacja na HTTP/2 w warstwie pośredniczącej, serializacja Protocol Buffers,
3. gRPC-Web Direct – bezpośrednia obsługa w oprogramowaniu pośredniczącym ASP.NET Core, bez serwera pośredniczącego, serializacja Protocol Buffers, protokół HTTP/2.

Na podstawie przeglądu literatury oraz analizy specyfikacji protokołów sformułowano następujące hipotezy badawcze:

H1: Warianty gRPC-Web osiągają niższe opóźnienie niż REST w komunikacji typu żądanie–odpowiedź, a przewaga ta rośnie wraz z rozmiarem odpowiedzi, ponieważ binarna serializacja Protocol Buffers redukuje wolumen przesyłanych danych względem formatu JSON [16].

H2: Przy odpowiedziach o niewielkim rozmiarze różnice pomiędzy protokołami są praktycznie nieistotne, ponieważ w komunikacji przez łącze rozległe czas odpowiedzi zdominowany jest przez opóźnienie propagacji, wspólne dla wszystkich protokołów.

H3: Przewaga wydajnościowa protokołu gRPC-Web wynika przede wszystkim z redukcji wolumenu przesyłanych danych, a nie z wersji protokołu transportowego HTTP. Hipoteza ta jest weryfikowalna, ponieważ wariant z serwerem Envoy Proxy przesyła ładunek Protocol Buffers przy użyciu protokołu HTTP/1.1 (analogicznie do REST), stanowiąc wariant kontrolny umożliwiający wyizolowanie wpływu formatu serializacji od wpływu protokołu transportowego.

H4: W operacjach modyfikacji stanu (ścieżka zapisu) różnice wydajnościowe pomiędzy protokołami stają się pomijalne, ponieważ całkowity czas odpowiedzi jest zdominowany przez czas wykonania transakcji bazodanowej.

H5: Wariant gRPC-Web Direct osiąga niższe opóźnienie niż wariant z proxy Envoy, ponieważ eliminuje dodatkowy skok sieciowy oraz koszt translacji realizowanej w odrębnym procesie.

7.2 Adaptacja systemu na potrzeby eksperymentu

Platforma testowa, której pełną architekturę i wdrożenie opisano w poprzednim rozdziale, wymagała wprowadzenia dedykowanych rozwiązań inżynierskich na potrzeby procedury badawczej. Modyfikacje te podporządkowano zasadzie kontroli zmiennych oraz eliminacji czynników zakłócających, co pozwoliło wyizolowanie wielu aspektów narzutu poszczególnych protokołów komunikacyjnych.

Izolacja zmiennych i symetria przetwarzania

Rzetelna ocena narzutu protokołów transportowych wymagała wyeliminowania asymetrii w sposobie przetwarzania danych po stronie serwera oraz odseparowania kosztu transmisji sieciowej od czasu operacji wejścia-wyjścia w warstwie bazodanowej.

Punkt odniesienia o zerowym narzucie wejścia-wyjścia (scenariusz Echo)

W celu zbadania czystego kosztu serializacji, deserializacji oraz nagłówek

protokołów zaimplementowano punkt końcowy `/api/echo` oraz odpowiadającą mu procedurę gRPC `EchoProducts`. Zwracają one kolekcję obiektów generowaną bezpośrednio w pamięci operacyjnej, pomijając zapytania do bazy PostgreSQL oraz pamięci podręcznej Redis. Listing 7.1 przedstawia implementację tego punktu końcowego.

```
1 app.MapGet("/api/echo", (int count = 200) =>
2 {
3     var products = Enumerable.Range(1, count).Select(i => new
4     {
5         id = i.ToString(),
6         name = $"Echo_Product_{i}",
7         description = $"This_is_a_hardcoded_echo_product_number_{i}_for_
8             benchmarking_protocol_overhead",
9         price = 9.99 * i,
10        categoryId = "echo",
11        stock = 100
12    });
13    return Results.Ok(new { products, totalCount = count });
14 });
```

Listing 7.1: Punkt końcowy Echo izolujący narzut protokołu od warstwy danych

Zapewnienie symetrii pamięci podręcznej W scenariuszach odczytu katalogu produktów z wykorzystaniem pamięci podręcznej wyeliminowano asymetrię formatów. Zamiast przechowywać dokumenty JSON i wymuszać wielokrotną konwersję po stronie gRPC, w magazynie Redis umieszczono binarną postać wiadomości Protocol Buffers. W efekcie obie badane ścieżki wykonują dokładnie jedną operację deserializacji przy trafieniu w pamięć podręczną, co gwarantuje, że zmierzone różnice czasowe wynikają wyłącznie ze specyfiki protokołu sieciowego.

Dobór wolumenu danych testowych Baza danych katalogu produktów została zainicjalizowana zbiorem 2000 rekordów. Wartość ta wyznacza górną granicę rozmiaru strony wyników, co umożliwia generowanie odpowiedzi o rozmiarze przekraczającym 260 kB. Pozwala to na weryfikację zachowania protokołów przy przekroczeniu początkowego okna przeciążenia TCP (ang. *Initial Congestion Window*).

Aplikacja kliencka jako narzędzie pomiarowe

Podstawowym założeniem metodologicznym pracy jest wykorzystanie rzeczywistego środowiska przeglądarki internetowej w roli klienta pomiarowego. Zastosowanie dedykowanych bibliotek generatorów obciążenia odtwarzałoby ruch sieciowy, lecz pomijało kluczowe elementy determinujące wydajność aplikacji webowej:

narzut silnika JavaScript, koszt deserializacji w pamięci przeglądarki oraz cykl renderowania drzewa DOM.

Do realizacji pomiarów wykorzystano aplikację kliencką we frameworku Angular 20, działającą w architekturze bezstrefowej (ang. *zoneless*). Wyeliminowanie biblioteki Zone.js pozwoliło usunąć wewnętrzny narzut modyfikacji zdarzeń asynchronicznych, który mógłby zafałszować pomiary czasu wykonania żądań. Komunikację zrealizowano przy użyciu biblioteki Connect RPC [29].

Wykonanie scenariuszy testowych pod zadaniem obciążeniem zautomatyzowano przy użyciu biblioteki Playwright [28], kontrolującej przeglądarkę Chromium w trybie bezokienkowym. Każdy równoległy wątek testowy uruchamiano w izolowanym kontekście przeglądarki z odrębnym magazynem sesji i pamięcią podręczną, co zapobiegało interferencji pomiędzy równoległymi pomiarami.

7.3 Metodyka pomiaru

Czas wykonania żądań mierzono bezpośrednio w kontekście wykonawczym strony przy użyciu interfejsu `performance.now()`. Jest to zegar przeznaczony do pomiarów wydajnościowych, którego rozdzielczość jest wystarczająca do rejestrowania czasów odpowiedzi uzyskiwanych w przeprowadzonych testach.

Początek pomiaru wyznacza moment rozpoczęcia obsługi żądania przez aplikację, natomiast jego koniec odpowiada chwili, w której dane otrzymane z serwera zostają naniesione na drzewo dokumentu (DOM). Do wykrycia tego momentu wykorzystano mechanizm stosowany w aplikacji Angular. Po zakończeniu aktualizacji widoku komponent inkrementuje atrybut `data-load-id`, którego zmianę obserwuje instancja `MutationObserver` działająca w tym samym wątku interfejsu.

Pomiar wykonany bezpośrednio w stronie pozwala uniknąć konieczności zewnętrznego odpytywania stanu drzewa DOM za pośrednictwem protokołu Chrome DevTools (CDP) [30]. W przypadku takiego rozwiązania cykliczne odpytywanie (ang. *polling*) wiązałoby się z dodatkową komunikacją pomiędzy narzędziem sterującym a przeglądarką.

Takie podejście pozwoliło ograniczyć wpływ zewnętrznych narzędzi na wyniki pomiarów oraz zastosować ten sam sposób wyznaczania końca pomiaru dla wszystkich badanych wariantów komunikacji. Rejestrowany czas obejmuje obsługę żądania po stronie aplikacji, w tym odbiór odpowiedzi, jej deserializację oraz aktualizację widoku.

Sterowanie scenariuszem

Parametry scenariusza (rozmiar strony wyników, stan pamięci podręcznej, liczba pozycji zamówienia oraz rozmiar odpowiedzi punktu końcowego Echo) przekazy-

wane są aplikacji przez parametry adresu URL. Rozwiązanie to zapewnia, że każda konfiguracja macierzy badawczej jest osiągalna zarówno automatycznie, jak i ręcznie, przez otwarcie odpowiedniego adresu w przeglądarce, co ułatwia weryfikację poprawności pomiaru.

Kontrola czynników zakłócających

W projekcie eksperymentu zastosowano sześć mechanizmów ograniczających wpływ czynników niebędących przedmiotem badania.

Rozgrzewka. Przed rozpoczęciem pomiarów wykonywanych jest dwadzieścia żądań na każdy protokół w każdym scenariuszu. Celem jest doprowadzenie kompilacji just-in-time platformy .NET oraz pul połączeń do stanu ustalonego.

Zapytania przygotowawcze. W każdej komórce macierzy każdy z równoległych klientów wykonuje trzy nierejestrowane żądania. Wypełniają one pamięć podręczną dla danego rozmiaru strony, dzięki czemu scenariusz z ciepłą pamięcią podręczną nie rozpoczyna się od chybienia.

Rotacja kolejności protokołów. Kolejność, w jakiej badane są protokoły, zmienia się między przebiegami zgodnie ze schematem kwadratu łacińskiego. Zabieg ten eliminuje systematyczne uprzywilejowanie protokołu mierzonego jako ostatni, korzystającego z systemu doprowadzonego już do stanu ustalonego. Jest to błąd znany w literaturze przedmiotu jako efekt kolejności [32].

Przerwy między przebiegami. Pomiędzy kolejnymi przebiegami całej macierzy stosowana jest przerwa piętnastu sekund, umożliwiająca ustabilizowanie mechanizmu odświeżania pamięci oraz pul połączeń.

Adaptacyjny czas namysłu. Pomiędzy kolejnymi żądaniami tego samego klienta zachowywana jest przerwa odwzorowująca czas namysłu użytkownika. Wartość tej przerwy nie jest stała, lecz wyliczana dla każdej komórki macierzy tak, aby zapotrzebowanie na pasmo nie przekroczyło połowy zmierzonej przepustowości łącza.

Wykluczenie obsługi z pamięci podręcznej przeglądarki. Powtarzane żądania o identycznym adresie mogłyby teoretycznie zostać obsłużone lokalnie, bez udziału sieci, co unieważniłoby pomiar. Odpowiedzi nie zawierają nagłówek ustanawiających okres świeżości, przeglądarka nie ma zatem podstaw do ponownego użycia zapisanej treści, a każdy kontekst dysponuje ponadto własną, odrębną pamięcią podręczną.

Budżet pasma łącza klienta

Zapotrzebowanie pojedynczej komórki macierzy na pasmo jest iloczynem liczby równoległych klientów i rozmiaru odpowiedzi, podzielonym przez długość cyklu żądania.

Nasycenie łącza klienta byłoby w tym eksperymencie błędem szczególnie groźnym, ponieważ nie miałyby charakteru losowego. Czas transmisji rośnie proporcjonalnie do rozmiaru odpowiedzi, a warianty binarne przesyłają znacznie mniej bajtów niż REST. Wariant o większym ładunku ucierpiałby zatem bardziej, a zmierzona „przewaga protokołu” byłaby częściowo odzwierciedleniem przepustowości łącza, w kierunku zawyżającym wynik gRPC-Web. Eksperyment potwierdzałby wówczas hipotezę H1 z przyczyn, które nie mają z nią związku.

Ponieważ mierzoną wielkością jest opóźnienie pojedynczego żądania, a nie przepustowość, rozwiązaniem nie jest usuwanie konfiguracji, lecz zmniejszenie częstotliwości żądań. Czas namysłu wyliczany jest zatem z zależności

$$t = \max \left(100 \text{ ms}, \frac{n \cdot s}{0,5 \cdot B} \right), \quad (7.1)$$

gdzie t oznacza czas namysłu, n – liczbę równoległych klientów, s – rozmiar odpowiedzi w bajtach, a B – zmierzoną przepustowość łącza wyrażoną w bajtach na sekundę. Pominięcie opóźnienia w mianowniku czyni oszacowanie zachowawczym: rzeczywisty cykl jest dłuższy od wyliczonego, a zatem faktyczne obciążenie łącza niższe od przyjętego budżetu.

Dla operacji zapisu przyjęto odrębny, niższy budżet, ponieważ scenariusz ten obciąża kierunek wysyłania, słabszy na łączach asymetrycznych.

7.4 Scenariusze i macierz badawcza

Eksperyment obejmuje trzy kategorie scenariuszy, z których każda bada inny aspekt wydajności systemu.

Scenariusz Echo – narzut protokołu

Scenariusze Echo stanowią fundament eksperymentu, ponieważ izolują koszt protokołu od kosztu warstwy danych. Odpowiedź generowana jest w pamięci, bez udziału bazy danych i pamięci podręcznej. Scenariusz ten świadomie nie renderuje pozycji w postaci tabeli.

Scenariusz Products – odczyt katalogu

Scenariusze Products odwzorowują realistyczny odczyt katalogu produktów z pełnym łańcuchem przetwarzania: żądanie trafia do usługi, obsługiwane jest z pamięci podręcznej Redis albo, przy wymuszonym pominięciu pamięci podręcznej, z bazy PostgreSQL, po czym wynik podlega serializacji, przesłaniu, deserializacji w przeglądarce i naniesieniu na interfejs.

Stan pamięci podręcznej sterowany jest nagłówkiem `X-Bypass-Cache`, którego obecność wymusza zapytanie do bazy danych. Rozwiązanie to pozwala badać oba stany bez restartu systemu.

Scenariusz Orders – zapis zamówienia

Scenariusze Orders badają operacje zapisu angażujące pełen łańcuch transakcyjny: walidację i zapis encji zamówienia wraz z pozycjami. Pozycje zamówienia losowane są z puli produktów inicjalizacyjnych, co zapewnia realistyczny rozkład rozmiaru żądania.

Wymiary macierzy

Tabela 7.1 przedstawia wymiary macierzy badawczej.

Tabela 7.1: Wymiary macierzy badawczej

Wymiar	Wartości
Protokoły	REST, gRPC-Web/Envoy, gRPC-Web/Direct
Liczba równoległych klientów	10, 20
Rozmiar odpowiedzi Echo	10, 100, 200, 500, 2000 rekordów
Rozmiar strony Products	10, 100, 200, 500, 1000, 2000 produktów
Stan pamięci podręcznej	ciepła (Redis), zimna (PostgreSQL)
Pozycje zamówienia	1, 10, 50, 200
Liczba powtórzeń macierzy	5
Żądań na klienta w komórce	20

Macierz obejmuje 39 konfiguracji, co przy trzech protokołach i pięciu powtórzeniach daje 585 wykonanych testów oraz 171 tysięcy zarejestrowanych pomiarów. Łączny czas przebiegu wyniósł 69,7 minuty. Odrzucono pięć konfiguracji, w których iloczyn obciążenia i rozmiaru odpowiedzi przekraczał przyjęty próg.


Liczba powtórzeń macierzy równa pięciu pozwala wyznaczyć odchylenie standardowe median przebiegów, a zatem ocenić powtarzalność pomiaru, nie zaś wyłącznie jego wartość centralną.

Liczbę żądań na klienta ustalono na dwadzieścia, co przy badanych poziomach obciążenia daje od 200 do 400 próbek na komórkę w jednym przebiegu, a zatem od 1000 do 2000 próbek na konfigurację i protokół po uwzględnieniu wszystkich powtórzeń.

7.5 Środowisko testowe

Konfiguracja sprzętowa i sieciowa

System testowany wdrożono na serwerze chmury Hetzner Cloud o ośmiu rdzeniach wirtualnych i 16 GB pamięci, zlokalizowanym w Norymberdze, pracującym pod kontrolą systemu Ubuntu 24.04.




Rysunek 7.1: Konsola Hetzner Cloud – parametry serwera, na którym wdrożono system testowany

Parametry maszyny w postaci udostępnianej przez konsolę dostawcy przedstawia rysunek 7.1. Jest to instancja typu CX43 o ośmiu rdzeniach wirtualnych, 16 GB pamięci i dysku lokalnym o pojemności 160 GB, umieszczona w strefie eu-central.

Klientem pomiarowym jest stacja robocza autora, łącząca się z serwerem przez publiczną sieć rozległą. Taka konfiguracja stanowi świadomy wybór metodologiczny. Umieszczenie klienta i serwera w jednym centrum danych, połączonych siecią prywatną, minimalizuje wprowadzenie zmienności pomiaru, lecz jednocześnie usuwa czynnik, który jak wykazano w rozdziale 8, decyduje o różnicach pomiędzy protokołami. Przewaga formatu binarnego ujawnia się bowiem poprzez liczbę wymian pakietów niezbędnych do przesłania odpowiedzi, a koszt każdej z nich jest proporcjonalny do opóźnienia łącza. Pomiar w sieci lokalnej systematycznie zaniżałby zatem badane zjawisko, prowadząc do wniosku, że wybór protokołu pozostaje bez znaczenia.

Stanowisko klienckie stanowi komputer o procesorze AMD Ryzen 7 5700X (8 rdzeni, 16 wątków logicznych, częstotliwość bazowa 3,4 GHz) oraz 32 GB pamięci operacyjnej, pracujący pod kontrolą systemu Microsoft Windows 11 (kompila-



Rysunek 7.2: Wykorzystanie procesora oraz przepustowość dysku serwera w trakcie pracy systemu pod obciążeniem (pulpit konsoli Hetzner Cloud)

cja 26200).

Parametry stanowiska klienckiego mają znaczenie dla interpretacji wyników, ponieważ, jak wykazano w sekcji 8.7, przy wyższych poziomach współbieżności czynnikiem ograniczającym przepustowość pomiaru było stanowisko klienckie, nie system testowany. Liczba rdzeni fizycznych stanowi przy tym prawdopodobny mechanizm tego zjawiska: każdy równoległy użytkownik odwzorowany jest odrębnym kontekstem przeglądarki z własnym wątkiem renderującym, zatem już przy dwudziestu kontekstach liczba wątków wykonujących pracę obliczeniową przewyższa liczbę dostępnych rdzeni. Samego poziomu granicznego nie określono jednak na podstawie liczby rdzeni. Został on wyznaczony eksperymentalnie poprzez obserwację zachowania stanowiska klienckiego przy rosnącym poziomie współbieżności, zgodnie z metodą opisaną w przywołanej sekcji.

Zmierzona charakterystyka łącza

Parametry łącza wyznaczono pomiarowo, ponieważ stanowią one wielkość wejściową dla mechanizmu opisanego w sekcji 7.3 oraz punkt odniesienia dla interpretacji wyników. Pomiar powtórzono trzykrotnie, rozrzut wyników nie przekroczył pięciu procent.

Zestawienie to ujawnia zależność o zasadniczym znaczeniu dla całej analizy: przepustowość pojedynczego połączenia ograniczona jest do około 20 Mbit/s, mimo że przepustowość zagregowana skaluje się niemal liniowo i przy szesnastu strumieniach nie osiągnęła jeszcze wartości granicznej. Ograniczeniem pojedynczego żądania nie jest zatem pojemność łącza, lecz iloczyn opóźnienia i przepustowości, omówiony w sekcji 8.2. Pomiar wysyłania daje wartość niemal identyczną, co wskazuje na symetryczne działanie tego mechanizmu w obu kierunkach.

Tabela 7.2: Zmierzona charakterystyka łącza klient–serwer

Wielkość	Wartość
Opóźnienie obiegu pakietu (RTT)	26,2–26,9 ms (zakres 24–30 ms)
Pobieranie, jeden strumień	19,6–20,8 Mbit/s
Pobieranie, cztery strumienie	74–79 Mbit/s
Pobieranie, osiem strumieni	143–146 Mbit/s
Pobieranie, szesnaście strumieni	269–273 Mbit/s
Wysyłanie, jeden strumień	19,2 Mbit/s

Wartości uzyskane z pojedynczego strumienia stanowią dolne ograniczenie pojemności łącza, nie jej miarę: różnica pomiędzy 20 a 273 Mbit/s w pobieraniu jest tego bezpośrednią ilustracją.

Zweryfikowana warstwa transportowa

Wersję protokołu HTTP negocjowaną przez przeglądarkę na każdej ze ścieżek zweryfikowano pomiarowo, korzystając z protokołu Chrome DevTools [30]. Wyniki przedstawia tabela 7.3.

Tabela 7.3: Zweryfikowana warstwa transportowa poszczególnych ścieżek komunikacji

Ścieżka	Port	Wersja HTTP	Połączeń TCP
REST	:5000	http/1.1	1
gRPC-Web przez Envoy	:8080	http/1.1	1
gRPC-Web Direct	:5002	h2	1

W przeprowadzonych testach ścieżka bezpośrednia korzystała z protokołu HTTP/2 negocjowanego za pomocą mechanizmu ALPN w ramach połączenia TLS, natomiast pozostałe dwie ścieżki wykorzystywały HTTP/1.1. Różnica ta wynika z właściwości badanych rozwiązań, ponieważ natywne gRPC korzysta z HTTP/2. Wariant gRPC-Web z proxy Envoy pozwala natomiast przysyłać ładunek binarny przy wykorzystaniu po stronie przeglądarki protokołu HTTP/1.1. Umożliwia to porównanie wariantów różniących się zarówno formatem serializacji, jak i warstwą transportową.

7.6 Metryki i sposób agregacji wyników

Dla każdej komórki macierzy i każdego protokołu wyznaczane są: liczba pomiarów, wartość minimalna, średnia arytmetyczna, mediana, percentyle 90., 95. i 99., wartość maksymalna, przepustowość wyrażona liczbą zakończonych operacji na sekundę, liczba żądań zakończonych niepowodzeniem.

Miarą podstawową w analizie przedstawionej w rozdziale 8 jest mediana, nie średnia arytmetyczna. Wybór ten wynika z odporności mediany na pojedyncze wartości odstające, które mogą pojawić się w pomiarach czasu odpowiedzi. Dzięki temu pojedyncze nietypowo wysokie wartości mają mniejszy wpływ na wartość reprezentującą typowy czas wykonania operacji.

Percentyl 95. nie został przyjęty jako główna miara porównawcza, ponieważ jest silniej zależny od zachowania górnego ogona rozkładu. Wartości percentyli 90., 95. i 99. są jednak zapisywane dla każdej komórki macierzy i mogą być wykorzystane w dodatkowej analizie rozkładu czasów odpowiedzi.

Powtarzalność pomiaru wyrażono współczynnikiem zmienności median pięciu przebiegów, zdefiniowanym jako iloraz odchylenia standardowego i średniej. Ze względu na niewielką liczbę powtórzeń zastosowano odchylenie standardowe z próby, z dzielnikiem $n - 1$, stanowiące estymator odchylenia populacyjnego.

Przy interpretacji przepustowości konieczne jest jedno zastrzeżenie. Ponieważ czas namysłu jest wyliczany osobno dla każdej komórki macierzy, wartości przepustowości nie są porównywalne pomiędzy komórkami. Pozostają natomiast w pełni porównywalne pomiędzy protokołami w obrębie jednej komórki, ponieważ w jej ramach czas namysłu jest identyczny. użytą wartość zapisano w wynikach dla każdej komórki. Zastrzeżenie to nie dotyczy opóźnień.

Wyniki zapisywane są w formacie JSON, obejmującym zarówno statystyki zbiorcze ze wszystkich przebiegów, jak i statystyki każdego przebiegu osobno, co umożliwia weryfikację, czy dana relacja pomiędzy protokołami zachodzi konsekwentnie, a nie wyłącznie w zestawieniu uśrednionym.

Przedziały ufności i kryterium rozstrzygalności

Ocena, czy zmierzona różnica pomiędzy protokołami jest rzeczywista, wymaga miary niepewności wartości centralnej, nie zaś wyłącznie miary rozrzutu. Zastosowano do tego przedziały ufności, przyjmując jako jednostkę analizy medianę pojedynczego przebiegu.

Wybór tej jednostki jest istotny metodycznie. Pomiary wykonane w obrębie jednego przebiegu nie są wzajemnie niezależne: dzielą stan pamięci podręcznej, ten sam kontekst przeglądarki oraz te same chwilowe warunki sieciowe. Wyznaczenie przedziału z kilkuset próbek jednej komórki dałoby zatem wynik pozornie precyzyjny, lecz nieuprawniony, ponieważ efektywna liczba niezależnych obserwacji jest znacznie mniejsza od liczby próbek. Niezależnych replikacji jest w eksperymencie pięć: tyle, ile przebiegów całej macierzy, każdy z odrębną kolejnością protokołów. Zgodnie z zasadami projektowania eksperymentów [32] to one stanowią jednostkę analizy.

Dla pięciu median przebiegów wyznaczono średnią $\bar{m}$ oraz odchylenie stan-

dardowe z próby s , a następnie dwustronny przedział ufności na poziomie 95%:

$$\bar{m} \pm t \cdot \frac{s}{\sqrt{k}}, \quad k = 5, \quad t = 2,776, \quad (7.2)$$

gdzie t oznacza wartość krytyczną rozkładu Studenta dla czterech stopni swobody. Przy pięciu obserwacjach mnożnik ten jest znacznie większy od wartości granicznej 1,96, co czyni oszacowanie zachowawczym.

Porównania pomiędzy protokołami przeprowadzono w układzie sparowanym. Ponieważ w każdym przebiegu mierzone są wszystkie trzy protokoły w tych samych warunkach, dla każdej pary wyznaczono pięć różnic w obrębie przebiegu. Parowanie eliminuje zmienność pomiędzy przebiegami, wspólną dla wszystkich protokołów, dzięki czemu przedział dla różnicy jest istotnie węższy niż przedział wyznaczony z dwóch niezależnych szeregów.

Przyjęto następujące kryterium rozstrzygalności: różnicę uznaje się za rozstrzygniętą, jeżeli jej przedział ufności nie zawiera zera. Kryterium to zastąpiło wcześniejszą regułę opartą na progu procentowym, ponieważ wiąże ocenę wprost ze zmiennością danych, a nie z wartością przyjętą arbitralnie.

Test rangowy dla par nie został zastosowany, ponieważ przy pięciu obserwacjach najmniejsza osiągalna dwustronna wartość prawdopodobieństwa wynosi 0,0625, a zatem test ten nie mógłby wykazać istotności na przyjętym poziomie niezależnie od wielkości efektu. Z tego względu raportowane są przedziały ufności, nie wartości prawdopodobieństwa testowego.

Rozdział 8

Porównawcza analiza wydajności gRPC vs REST

Niniejszy rozdział przedstawia wyniki eksperymentu przeprowadzonego zgodnie z metodologią opisaną w rozdziale 7. Analiza rozpoczyna się od wielkości niezależnych od warunków sieciowych: wolumenu przesyłanych danych oraz wynikającego z niego modelu liczby wymian pakietów. Dopiero one pozwalają zinterpretować zmierzone czasy odpowiedzi. Następnie omówione zostają kolejno scenariusze Echo, Products i Orders, rozdzielenie wpływu serializacji od wpływu wersji protokołu HTTP, granica przepustowości stanowiska pomiarowego, powtarzalność wyników wraz z przedziałami ufności wyznaczonymi dla zmierzonych różnic oraz mechanizmy kontrolne potwierdzające wiarygodność uzyskanych rezultatów. Rozdział zamyka weryfikacja hipotez oraz rekomendacje architektoniczne wraz z wytycznymi wdrożeniowymi.

8.1 Wolumen przesyłanych danych

Rozmiary odpowiedzi wyznaczono pomiarowo na wdrożonym systemie, zestawiając liczbę bajtów zwracanych przez punkt końcowy REST oraz przez usługę gRPC dla identycznego zapytania. Wyniki przedstawia tabela 8.1.

Serializacja binarna redukuje wolumen przesyłanych danych o 42,8–43,4% w scenariuszu Products oraz o 32,8–33,5% w scenariuszu Echo. Stabilność współczynnika względem liczby rekordów potwierdza jego systematyczny charakter.

Wpływ kompresji treści na wolumen danych

Wszystkie rozmiary przedstawione w tabeli 8.1 dotyczą treści nieskompresowanej. W badanym systemie kompresja ciała odpowiedzi nie została włączona na żadnej ze ścieżek: usługi nie korzystają z oprogramowania pośredniczącego kompresji, a konfiguracja serwera pośredniczącego nie zawiera filtra kompresora. W ta-

Tabela 8.1: Zmierzony rozmiar odpowiedzi [B] i redukcja uzyskana serializacją binarną

Scenariusz	Rekordów	JSON	Protocol Buffers	Redukcja
Products	10	1 328	752	43,4%
Products	200	26 405	14 998	43,2%
Products	500	66 556	38 054	42,8%
Products	1000	133 134	76 200*	42,8%*
Products	2000	265 159	151 700*	42,8%*
Echo	10	1 771	1 190	32,8%
Echo	200	36 242	24 104	33,5%

* wartość oszacowana przez ekstrapolację zmierzonego współczynnika redukcji

kim przypadku żaden z badanych wariantów nie jest uprzywilejowany. Odpowiada on przy tym domyślnym ustawieniom platformy ASP.NET Core oraz szkieletu gRPC dla .NET. Konsekwencje tego wyboru dla zakresu wniosków wymagają jednak omówienia, ponieważ w praktyce wdrożeniowej dokumenty JSON podawane są najczęściej z kompresją realizowaną przez serwer aplikacyjny, odwrotne proxy lub sieć dostarczania treści.

Wpływ kompresji oszacowano ilościowo dla scenariusza Echo, którego ładunek generowany jest w sposób deterministyczny. Poprawność odtworzenia zweryfikowano przez porównanie z rozmiarami zmierzonymi na wdrożonym systemie: dla 200 rekordów uzyskano 36 246 B wobec zmierzonych 36 242 B w formacie JSON oraz 24 079 B wobec 24 104 B w formacie binarnym, czyli odchylenie nieprzekraczające 0,1%. Wyniki kompresji algorytmem gzip przedstawia tabela 8.2.

Tabela 8.2: Rozmiar ładunku scenariusza Echo bez kompresji i po kompresji gzip [B] oraz wynikająca z niego liczba okien odbiorczych

Rek.	JSON	JSON gz	protobuf	protobuf gz	Okien JSON gz	Okien protobuf
200	36 246	2 964	24 079	2 523	0,05	0,37
500	91 247	7 129	60 679	5 986	0,11	0,93
2000	370 255	27 715	246 682	22 686	0,42	3,76

Zestawienie prowadzi do dwóch wniosków o istotnym znaczeniu dla zakresu stosowalności wyników.

Po pierwsze, kompresja redukuje wolumen formatu tekstowego 12–13-krotnie, natomiast formatu binarnego 9,5–11-krotnie. Po jej zastosowaniu przewaga objętościowa serializacji binarnej maleje z 33% do 15–18%. Po drugie, i ważniejsze, po kompresji wszystkie badane ładunki mieszczą się w jednym oknie odbiorczym: przy 2000 rekordach skompresowany dokument JSON zajmuje 0,42 okna, wobec 3,76 okna wymaganych przez nieskompresowaną wiadomość binarną. Zgodnie z modelem przedstawionym w sekcji 8.2 oznacza to, że mechanizm odpowiadający za wykazaną w niniejszej pracy przewagę, czyli zmniejszenie liczby wymian

pakietów, w konfiguracji z kompresją nie zostałyby uruchomiony w całym badanym zakresie rozmiarów odpowiedzi. Pozostałaby wyłącznie różnica wynikająca z kosztu serializacji i deserializacji. Przewaga czasowa wykazana w niniejszym rozdziale dotyczy zatem transferów nieskompresowanych; jej przeniesienie na wdrożenie z kompresją włączoną wymagałoby odrębnego pomiaru.

8.2 Model liczby wymian pakietów

Zmierzona charakterystyka łącza (sekcja 7.5) ujawniła, że przepustowość pojedynczego połączenia wynosi około 20 Mbit/s, mimo że przepustowość zagregowana przekracza 270 Mbit/s. Iloczyn przepustowości i opóźnienia dla tego połączenia wynosi

$$20 \text{ Mbit/s} \cdot 0,0262 \text{ s} \approx 65\,500 \text{ B} \approx 64 \text{ KiB}, \quad (8.1)$$

co odpowiada rozmiarowi okna odbiorczego protokołu TCP bez zastosowania skalowania okna [31]. Przy oknie mniejszym od iloczynu przepustowości i opóźnienia przepustowość osiągalna w jednym połączeniu wynika z rozmiaru okna, nie z pojemności łącza. Czynnikiem ograniczającym pojedyncze żądanie nie jest zatem pojemność łącza, lecz ilość danych, jaką nadawca może wysłać przed otrzymaniem potwierdzenia: po wypełnieniu okna transmisja wstrzymuje się do nadejścia potwierdzenia od odbiorcy.

Zgodność wartości 64 KiB z iloczynem przepustowości i opóźnienia nie jest dowodem, lecz przesłanką: obie wielkości powiązane są tożsamością $B = W/\text{RTT}$: tym samym równaniem co w równaniu (8.1), zapisanym względem B zamiast W , a wyznaczenie jednej z drugiej stanowi jedynie przeliczenie. Rozstrzygające jest natomiast to, że wielkość ta przewiduje niezależnie zmierzone czasy odpowiedzi dla ładunków o różnym rozmiarze, co wykazano w dalszej części sekcji. Należy przy tym zaznaczyć, że identyczny schodkowy przebieg dawałby mechanizm powolnego startu protokołu TCP, w którym okno zatoru narasta w kolejnych obiegach pakietu. Rozstrzygnięcie, który z obu mechanizmów jest tu czynnikiem wiodącym, wymagałoby przechwycenia ruchu na poziomie pakietów, czego nie wykonano, dla wniosków pracy jest to jednak bez znaczenia, ponieważ oba prowadzą do tego samego przewidywania: koszt transmisji rośnie skokowo, o wielokrotność opóźnienia obiegu pakietu, wraz z przekraczaniem kolejnych wielokrotności rozmiaru okna.

Z zależności tej wynika model przewidujący czas transmisji odpowiedzi. Przesłanie odpowiedzi o rozmiarze s wymaga $\lceil s/64 \text{ KiB} \rceil$ okien, a każde okno ponad pierwsze kosztuje jedno dodatkowe opóźnienie obiegu pakietu. Przewidywana liczba dodatkowych obiegów wynosi zatem

$$n_{\text{RTT}} = \left\lceil \frac{s}{64 \text{ KiB}} \right\rceil - 1. \quad (8.2)$$

Model ten poddano weryfikacji ilościowej, przyjmując za punkt odniesienia konfigurację o 200 rekordach, w której odpowiedź obu formatów mieści się w jednym oknie. Nadwyżkę czasu względem tego punktu odniesienia podzielono przez zmierzone opóźnienie obiegu pakietu (26,2 ms). Wyniki przedstawia tabela 8.3.

Tabela 8.3: Weryfikacja modelu – przewidywana i zmierzona liczba dodatkowych obiegów pakietu

Scenariusz	Rekordów	Rozmiar [B]	Okien	Przewid.	Zmierz.
Echo, JSON	500	90 500*	1,38	1	1,04
Echo, JSON	2000	362 000*	5,52	5	5,15
Echo, protobuf	500	60 500*	0,92	0	0,10
Echo, protobuf	2000	242 000*	3,69	3	3,29
Products, JSON	500	66 556	1,02	1	0,97
Products, JSON	1000	133 134	2,03	2	1,89
Products, JSON	2000	265 159	4,05	4	3,83
Products, protobuf	500	38 054	0,58	0	0,08
Products, protobuf	1000	76 200*	1,16	1	1,06
Products, protobuf	2000	151 700*	2,31	2	2,19

* wartość wyznaczona przez ekstrapolację zmierzonego rozmiaru pojedynczego rekordu

Zgodność jest bardzo dobra we wszystkich dziesięciu przypadkach: różnica pomiędzy wartością przewidywaną a zmierzoną nie przekracza 0,2 obiegu, a w żadnym przypadku nie zmienia liczby całkowitej. Model wyjaśnia w szczególności zjawisko, którego nie sposób wyjaśnić samą przepustowością: różnica 30 kilobajtów pomiędzy formatami przy 500 rekordach scenariusza Echo odpowiadałaby przy przepustowości zagregowanej niespełna jednej milisekundy, a przy przepustowości pojedynczego strumienia, około dwunastu milisekund, natomiast zmierzona różnica wynosi 26 ms, czyli dokładnie jeden obieg pakietu.

Przewaga serializacji binarnej nie jest ciągłą funkcją rozmiaru odpowiedzi, lecz realizuje się skokowo: wyłącznie wtedy, gdy mniejszy ładunek wymaga mniejszej liczby okien. Ponadto wielkość tej przewagi jest proporcjonalna do opóźnienia łącza, nie do szybkości serwera: w sieci lokalnej, gdzie opóźnienie obiegu pakietu jest mniejsze od milisekundy, ten sam mechanizm dawałby korzyść pomijalną.


8.3 Analiza narzutu protokołu (Echo)

Scenariusze Echo izolują koszt protokołu od kosztu warstwy danych. Tabela 8.4 przedstawia zmierzone mediany opóźnień wraz ze współczynnikami zmienności.

Zależność tę przedstawia rysunek 8.1. Dane pozwalają na sformułowanie trzech obserwacji.

Tabela 8.4: Mediana opóźnień w scenariuszach Echo [ms]; w nawiasach współczynnik zmienności median pięciu przebiegów

VU	Rekordów	REST	Envoy	Direct	Direct vs REST
10	10	31,0 (0,7%)	32,6 (4,6%)	30,1 (2,9%)	−3%
10	100	32,1 (2,9%)	32,2 (1,5%)	30,8 (3,4%)	−4%
10	200	32,6 (1,1%)	33,3 (1,5%)	31,3 (1,3%)	−4%
10	500	59,8 (1,0%)	35,2 (1,8%)	33,8 (2,3%)	−43%
10	2000	167,6 (0,7%)	120,8 (1,8%)	117,4 (1,6%)	−30%
20	10	37,1 (5,7%)	34,8 (4,0%)	32,5 (3,6%)	−12%
20	100	39,0 (4,3%)	35,6 (6,9%)	33,0 (3,3%)	−15%
20	200	37,0 (5,6%)	34,9 (1,7%)	33,8 (3,0%)	−9%
20	500	60,6 (1,7%)	39,1 (6,0%)	35,5 (11,5%)	−41%



Rysunek 8.1: Mediana opóźnień w scenariuszach Echo względem liczby rekordów w odpowiedzi

Po pierwsze, do 200 rekordów włącznie różnice pomiędzy protokołami pozostają niewielkie, od trzech do piętnastu procent, przy wartościach bezwzględnych rzędu jednej do pięciu milisekund. Zgodnie z modelem z sekcji 8.2 odpowiedzi tego rozmiaru mieszczą się w jednym oknie w obu formatach; liczba obiegów pakietu jest zatem identyczna, a pozostała różnica wynika z narzutu ramkowania i warstwy transportowej.

Po drugie, przejście z 200 na 500 rekordów powoduje skokową zmianę obrazu. Opóźnienie REST rośnie z 32,6 do 59,8 ms, czyli o 27,2 ms, natomiast opóźnienie wariantu Direct – z 31,3 do 33,8 ms, czyli o 2,5 ms. Przewaga wariantu binarnego osiąga w tej konfiguracji 43%. Jest to najczystsze potwierdzenie modelu okna w całym eksperymencie: przyrost REST odpowiada dokładnie jednemu opóźnieniu obiegu pakietu, ponieważ dokument JSON o rozmiarze 90,5 kilobajta nie mieści się w jednym oknie, natomiast wiadomość binarna o rozmiarze 60,5 kilobajta – mieści.

Po trzecie, przy 2000 rekordach przewaga wynosi 30%, czyli zbliża się do zmierzonego współczynnika redukcji wolumenu danych. Powyżej kilku okien

liczba obiegów staje się w przybliżeniu proporcjonalna do rozmiaru odpowiedzi, a przewaga czasowa zbiega wówczas do przewagi objętościowej.

Współczynniki zmienności nie przekraczają w tej grupie 6,9%, z jednym wyjątkiem na poziomie 11,5%. Wszystkie omówione relacje zachodzą konsekwentnie w każdym z pięciu przebiegów.

8.4 Analiza wydajności odczytu (Products)

Scenariusze Products badają wydajność w realistycznym kontekście odczytu katalogu, z pełnym łańcuchem obejmującym pamięć podręczną lub bazę danych, deserializację w przeglądarce oraz aktualizację interfejsu.


Odczyt z ciepłą pamięcią podręczną

Tabela 8.5: Mediana opóźnienia w scenariuszach Products, ciepła pamięć podręczna [ms]; w nawiasach współczynnik zmienności median pięciu przebiegów

VU	PageSize	REST	Envoy	Direct	Direct vs REST
10	10	33,6 (6,7%)	34,9 (2,0%)	31,7 (2,7%)	−6%
10	100	39,2 (8,0%)	41,7 (6,3%)	39,0 (2,6%)	−1%
10	200	40,3 (3,7%)	42,0 (5,7%)	39,0 (5,0%)	−3%
10	500	65,8 (0,6%)	42,3 (4,5%)	41,1 (3,5%)	−38%
10	1000	89,9 (1,4%)	69,4 (4,5%)	66,9 (1,0%)	−26%
10	2000	140,6 (1,6%)	97,5 (1,8%)	96,5 (1,4%)	−31%
20	10	40,9 (4,6%)	37,5 (6,2%)	34,4 (1,4%)	−16%
20	100	45,5 (2,9%)	45,2 (3,0%)	43,6 (7,2%)	−4%
20	200	46,2 (3,0%)	45,9 (3,0%)	44,4 (4,5%)	−4%
20	500	71,8 (1,5%)	48,4 (2,8%)	44,4 (3,1%)	−38%
20	1000	94,3 (2,4%)	70,5 (1,6%)	70,2 (2,2%)	−26%

Obraz uzyskany w scenariuszu Echo przenosi się na realną ścieżkę odczytu bez istotnych zmian, co ilustruje rysunek 8.2. Do 200 produktów na stronę różnice mieszczą się w przedziale od jednego do szesnastu procent, natomiast od 500 produktów przewaga wariantów binarnych stabilizuje się na poziomie 26–38%. Zgodność z przewidywaniami modelu (tabela 8.3) jest w tej grupie równie dobra jak w scenariuszu Echo.

Wynik ten jest istotny metodycznie, ponieważ scenariusz Products obejmuje wszystkie składniki obecne w docelowym zastosowaniu: dostęp do pamięci podręcznej, serializację po stronie serwera, transmisję, deserializację w silniku JavaScript oraz aktualizację drzewa dokumentu. Utrzymanie się przewagi w tych warunkach wskazuje, że nie jest ona artefaktem uproszczonego scenariusza.



Rysunek 8.2: Mediana opóźnień w scenariuszach Products z ciepłą pamięcią podręczną, dla dziesięciu i dwudziestu równoległych klientów; słupki błędów odpowiadają 95% przedziałowi ufności wartości centralnej.


Pomiar przy dwudziestu klientach daje ten sam obraz relacji przy systematycznie wyższych wartościach bezwzględnych. Powtarzalność wyników w tej grupie jest wysoka: współczynnik zmienności nie przekracza ośmiu procent. Charakterystyczne jest przy tym, że najwyższa zmienność występuje przy najmniejszych ładunkach, gdzie mierzona wartość jest zdominowana przez opóźnienie propagacji, a zatem podlega wahaniom warunków sieciowych w większym stopniu względnym.

Odczyt z zimną pamięcią podręczną

Tabela 8.6: Mediana opóźnień w scenariuszach Products, zimna pamięć podręczna [ms]; w nawiasach współczynnik zmienności.

VU	PageSize	REST	Envoy	Direct
10	10	36,8 (51,3%)	38,5 (46,7%)	36,7 (41,4%)
10	100	84,9 (25,7%)	83,8 (24,4%)	80,1 (28,5%)
10	200	82,8 (27,0%)	47,6 (40,9%)	89,9 (4,7%)
10	500	76,7 (14,2%)	55,6 (33,5%)	75,6 (33,2%)
10	1000	100,5 (4,6%)	91,9 (3,5%)	90,0 (11,0%)
10	2000	187,5 (13,5%)	111,3 (7,7%)	116,0 (6,2%)
20	500	89,1 (10,0%)	62,4 (30,9%)	78,3 (21,6%)
20	1000	106,3 (8,9%)	109,2 (10,8%)	111,3 (17,7%)

Grupa ta wymaga ostrożnej interpretacji. Wymuszenie zapytania do bazy danych przy każdym żądaniu zwiększa nie tylko opóźnienie, lecz przede wszystkim jego zmienność: współczynnik zmienności osiąga w skrajnych przypadkach 51%, wobec kilku procent w scenariuszach z ciepłą pamięcią podręczną. W konsekwencji



Rysunek 8.3: Mediana opóźnień w scenariuszach Products z zimną pamięcią podręczną; słupki błędów odpowiadają 95% przedziałowi ufności wartości centralnej

przy małych stronach wyników kolejność protokołów jest niestabilna: w konfiguracji o 200 produktach zmierzone mediany wynoszą 82,8, 47,6 i 89,9 ms, a uporządkowanie to nie powtarza się w konfiguracji o 10 produktach. Różnice te mieszczą się w granicach zmienności tej grupy i nie pozwalają wskazać szybszego protokołu. Zależność tę wraz z przedziałami ufności wartości centralnej przedstawia rysunek 8.3.

Przy dużych stronach wyników przewaga wariantów binarnych przewyższa poziom szumu. Przy 2000 produktach REST osiąga 187,5 ms, wariant z proxy 111,3 ms, a wariant bezpośredni 116,0 ms, przy współczynniku zmienności nieprzekraczającym 13,5%.

Wniosek metodyczny jest następujący: przy małych ładunkach zmienność wynikająca z zimnej pamięci podręcznej przewyższa różnicę wynikającą z protokołu, przez co ta grupa nie stanowi użytecznego narzędzia porównawczego. Do izolowania wpływu protokołu służy scenariusz Echo, natomiast do oceny zachowania w warunkach realnych – scenariusz z ciepłą pamięcią podręczną.


8.5 Analiza wydajności zapisu (Orders)

Scenariusze Orders angażują pełen łańcuch transakcyjny: walidację oraz zapis encji zamówienia wraz z pozycjami.

Scenariusze zapisu nie wykazują spójnej różnicy pomiędzy protokołami. Przy dziesięciu i pięćdziesięciu pozycjach zamówienia wszystkie trzy warianty mieszczą się w przedziale 83,5–106,2 ms, mimo że rozmiar żądania zmienia się pięciokrotnie. Przy dwustu pozycjach kolejność jest odmienna dla dwóch badanych poziomów obciążenia, a współczynniki zmienności sięgają czterdziestu procent. Zestawienie median wraz z przedziałami ufności wartości centralnej przedstawia rysunek 8.4.

Tabela 8.7: Mediana opóźnień w scenariuszach Orders [ms]; w nawiasach współczynnik zmienności

VU	Pozycji	REST	Envoy	Direct
10	1	85,4 (29,9%)	40,6 (50,7%)	35,6 (54,8%)
10	10	94,2 (3,5%)	89,1 (29,9%)	89,6 (40,3%)
10	50	94,5 (2,5%)	96,1 (0,7%)	91,8 (22,0%)
10	200	203,4 (39,1%)	225,9 (32,3%)	237,8 (32,1%)
20	1	79,3 (39,8%)	43,8 (40,1%)	43,1 (47,9%)
20	10	83,5 (35,0%)	89,9 (26,7%)	89,7 (4,9%)
20	50	106,2 (40,0%)	101,2 (6,9%)	165,8 (21,6%)
20	200	384,9 (16,6%)	334,7 (28,3%)	268,2 (28,4%)



Rysunek 8.4: Mediana opóźnień w scenariuszach Orders względem liczby pozycji zamówienia; słupki błędu odpowiadają 95% przedziałowi ufności wartości centralnej

Wyjaśnienie wyniku bezpośrednio z modelu przedstawionego w sekcji 8.2 oraz z charakteru ścieżki zapisu. Żądania w tym scenariuszu są niewielkie: nawet dwieście pozycji zamówienia to około siedemnastu kilobajtów, czyli znacznie mniej niż okno odbiorcze. Liczba obiegów pakietu jest zatem identyczna dla wszystkich formatów, a mechanizm dający przewagę w odczycie nie ma tu zastosowania. Jednocześnie czas odpowiedzi zdominowany jest przez stały koszt serwerowy: transakcję bazodanową obejmującą zapis encji.


Obserwacja ta stanowi wynik negatywny, lecz metodycznie istotny: wskazuje granicę stosowności wniosków wyprowadzonych ze scenariuszy odczytu. Optymalizacja warstwy transportowej nie przyniesie korzyści w operacjach, których czas wyznaczany jest przez trwałe utrwalanie danych.

8.6 Rozdzielenie wpływu serializacji od wpływu wersji protokołu HTTP

Ścieżka bezpośrednia korzysta z protokołu HTTP/2, natomiast REST – z HTTP/1.1. Zmierzona różnica pomiędzy nimi zawiera zatem dwa zmieszane czynniki: mniejszy wolumen danych oraz odmienną wersję protokołu transportowego. Rozdzielenie ich umożliwia wariant z proxy Envoy, który przenosi ładunek binarny, korzystając po stronie przeglądarki z protokołu HTTP/1.1, tak samo jak REST. Stanowi on tym samym grupę kontrolną: różnica pomiędzy REST a Envoy odzwierciedla wpływ samej serializacji, ponieważ obie ścieżki korzystają z nieszyfrowanego protokołu HTTP/1.1 i różnią się wyłącznie formatem serializacji. Różnica pomiędzy wariantem z proxy Envoy a ścieżką bezpośrednią odzwierciedla natomiast wpływ wersji protokołu HTTP oraz pominięcia serwera pośredniczącego.

Tabela 8.8: Dekompozycja przewagi na składnik serializacyjny i transportowy [ms]

Konfiguracja	REST	Envoy	Direct	Serializ.	Transport
Echo, 2000 rek., VU=10	167,6	120,8	117,4	–28%	–2%
Products, PS=500, VU=10	65,8	42,3	41,1	–36%	–2%
Products, PS=1000, VU=10	89,9	69,4	66,9	–23%	–3%
Products, PS=2000, VU=10	140,6	97,5	96,5	–31%	–1%
Products, PS=500, VU=20	71,8	48,4	44,4	–33%	–6%



Rysunek 8.5: Udział składnika serializacyjnego oraz transportowego w skróceniu czasu odpowiedzi względem REST; wartości procentowe odniesiono do mediany opóźnienia REST

Wynik, przedstawiony graficznie na rysunku 8.5, jest jednoznaczny. W konfiguracji o 500 produktach na stronę z łącznej przewagi 24,7 ms aż 23,5 ms przypada na zmianę formatu serializacji, a zaledwie 1,2 ms na wersję protokołu HTTP wraz

z pominięciem serwera pośredniczącego. Udział składnika serializacyjnego w całkowitej przewodzie wynosi zatem około 95%. Zależność ta powtarza się we wszystkich badanych konfiguracjach: składnik transportowy nie przekracza sześciu procent, podczas gdy składnik serializacyjny mieści się w przedziale 23–36%.

Gdyby dominującym czynnikiem była wersja protokołu HTTP, wariant z proxy, korzystający z protokołu HTTP/1.1, osiągałby wyniki zbliżone do REST. Zmierzone wartości wskazują jednak, że wariant ten dorównuje ścieżce bezpośredniej, a nie ścieżce REST. Obserwacja ta stanowi bezpośrednie potwierdzenie hipotezy H3 i jednocześnie odpowiedź na zarzut, że porównanie zestawia protokół binarny po HTTP/2 z formatem tekstowym po HTTP/1.1.

8.7 Skalowanie z liczbą klientów i granica stanowiąca pomiarowego


Zakres badanych poziomów obciążenia wyznaczono na podstawie odrębnego pomiaru, którego celem było ustalenie, do jakiej liczby równoległych klientów stanowisko pomiarowe pozostaje wiarygodne. Wyniki dla konfiguracji o 100 produktach na stronę i ciepłej pamięci podręcznej przedstawia tabela 8.9.

Tabela 8.9: Skalowanie z liczbą równoległych klientów – mediana opóźnień [ms] i przepustowość [operacji/s]

VU	Mediana opóźnień [ms]			Przepustowość [oper./s]		
	REST	Envoy	Direct	REST	Envoy	Direct
10	38,1	41,4	39,5	40,7	40,7	38,3
20	50,9	50,0	44,5	40,8	58,7	59,3
30	64,8	61,8	54,9	72,3	69,9	68,3
50	140,3	122,5	113,2	75,4	63,8	64,6

Zestawienie, zilustrowane na rysunku 8.6, ujawnia klasyczny obraz nasycenia. Przepustowość wypłaszcza się na poziomie około siedemdziesięciu operacji na sekundę, osiągając wartość graniczną pomiędzy dwudziestoma a trzydziestoma klientami, natomiast opóźnienie nadal narasta, z 38 do 140 ms. Powyżej punktu przegięcia zwiększanie współbieżności wydłuża wyłącznie czas oczekiwania w kolejce, bez korzyści przepustowościowej.

Rozstrzygnięcie, po której stronie znajduje się czynnik ograniczający, opiera się na następującej przesłance: wszystkie trzy protokoły zatrzymują się na tej samej wartości granicznej, mimo że po stronie serwera realizowane są odmiennymi ścieżkami kodu: ścieżka REST zwraca gotowy dokument z pamięci podręcznej, natomiast ścieżki binarne wykonują deserializację i ponowną serializację. Gdyby ograniczenie leżało po stronie systemu testowanego, ścieżki te różniłyby się wartością



Rysunek 8.6: Opóźnienie i przepustowość względem liczby równoległych klientów; szary pas oznacza wspólny pułap przepustowości, różowy – położenie punktu przegięcia

graniczną. Wspólny pułap wskazuje zatem na czynnik po stronie klienta: rywalizację o zasoby pomiędzy kilkudziesięcioma kontekstami przeglądarki.

Wniosek ten stanowił podstawę ograniczenia macierzy badawczej do dziesięciu i dwudziestu klientów, to jest poniżej punktu przegięcia. Przyjęto zasadę, że waższy zakres współbieżności z wynikami wiarygodnymi jest wartościowszy niż zakres szerszy z wynikami opisującymi ograniczenia narzędzia.

8.8 Powtarzalność pomiarów i przedziały ufności

Pięciokrotne wykonanie całej macierzy umożliwia ocenę powtarzalności. Tabela 8.10 przedstawia rozkład współczynnika zmienności median przebiegów w poszczególnych grupach scenariuszy.

Tabela 8.10: Współczynnik zmienności median pięciu przebiegów, w podziale na grupy scenariuszy

Grupa scenariuszy	Minimum	Typowo	Maksimum
Echo	0,7%	1,5–5%	11,5%
Products, ciepła pamięć	0,6%	2–6%	8,0%
Products, zimna pamięć	3,5%	10–30%	51,3%
Orders	0,7%	20–40%	54,8%

Rozkład ten układa się w interpretowalny wzorec, zgodny z udziałem warstwy danych w czasie odpowiedzi. Najwyższą powtarzalność wykazują scenariusze Echo, nieodwołujące się do bazy ani pamięci podręcznej, oraz scenariusze odczytu z ciepłą pamięcią podręczną. Scenariusze wymuszające zapytanie do bazy oraz

scenariusze zapisu charakteryzują się zmiennością o rząd wielkości wyższą, ponieważ angażują mechanizmy trwałego utrwalania danych, dziennik transakcji oraz blokady wierszy.

Przedziały ufności i rozstrzygalność zmierzonych różnic

Zestawienia przedstawione w poprzednich sekcjach podają wartości centralne wraz z miarą rozrzutu. Ocena, czy zaobserwowana różnica jest rzeczywista, wymaga natomiast miary niepewności samej wartości centralnej.

Tabela 8.11: Przedziały ufności 95% dla wartości centralnej opóźnienia [ms]; $k = 5$ przebiegów, $t = 2,776$

Konfiguracja	REST	Envoy	Direct
Echo, 200 rek., VU=10	$32,5 \pm 0,4$	$33,4 \pm 0,6$	$31,4 \pm 0,5$
Echo, 500 rek., VU=10	$59,7 \pm 0,8$	$35,2 \pm 0,8$	$34,0 \pm 1,0$
Echo, 2000 rek., VU=10	$168,0 \pm 1,5$	$120,4 \pm 2,7$	$117,5 \pm 2,4$
Echo, 500 rek., VU=20	$60,6 \pm 1,3$	$39,7 \pm 3,0$	$37,0 \pm 5,3$
Products, PS=200, VU=10	$40,6 \pm 1,9$	$42,0 \pm 3,0$	$39,2 \pm 2,4$
Products, PS=500, VU=10	$65,8 \pm 0,5$	$42,3 \pm 2,4$	$40,8 \pm 1,8$
Products, PS=1000, VU=10	$90,0 \pm 1,5$	$69,9 \pm 3,9$	$66,9 \pm 0,8$
Products, PS=2000, VU=10	$140,8 \pm 2,7$	$97,5 \pm 2,2$	$96,8 \pm 1,6$
Products, PS=500, VU=20	$71,9 \pm 1,3$	$48,7 \pm 1,7$	$44,4 \pm 1,7$
Products, PS=1000, VU=20	$94,8 \pm 2,8$	$70,7 \pm 1,4$	$70,3 \pm 1,9$
Orders, 10 poz., VU=10	$93,2 \pm 4,1$	$81,3 \pm 30,2$	$73,7 \pm 36,9$
Orders, 50 poz., VU=10	$93,5 \pm 3,0$	$96,0 \pm 0,8$	$86,2 \pm 23,5$
Orders, 10 poz., VU=20	$72,0 \pm 31,3$	$83,0 \pm 27,5$	$89,1 \pm 5,4$
Orders, 50 poz., VU=20	$112,7 \pm 55,9$	$101,2 \pm 8,6$	$160,3 \pm 43,0$

W scenariuszach Echo oraz w odczycie z ciepłą pamięcią podręczną połówkowa szerokość przedziału nie przekracza kilku milisekund, natomiast w scenariuszach zapisu sięga kilkudziesięciu, przekraczając w skrajnym przypadku połowę samej wartości centralnej.

Zasadnicze znaczenie ma jednak zestawienie różnic pomiędzy protokołami w układzie sparowanym. Wartość dodatnia oznacza, że pierwszy z wymienionych protokołów jest wolniejszy, a zestawienie to pozwala sformułować cztery wnioski.

Po pierwsze, w każdej konfiguracji odczytu od 500 rekordów przewaga wariantów binarnych jest rozstrzygnięta z dużym marginesem: przedział dla różnicy REST–Direct wynosi na przykład $24,9 \pm 1,6$ ms przy 500 produktach oraz $50,5 \pm 3,3$ ms przy 2000 rekordach scenariusza Echo. Stosunek wielkości efektu do połówkowej szerokości przedziału przekracza w tych konfiguracjach dziesięć, co czyni wniosek odpornym również na przyjęte założenie o rozkładzie.

Po drugie, w zakresie małych ładunków obraz jest bardziej złożony, niż wskazywałaby sama wielkość różnicy. W scenariuszu Products przy 200 produktach róż-

Tabela 8.12: Przedziały ufności 95% dla różnic sparowanych w obrębie przebiegu [ms]; wartość dodatnia oznacza dłuższy czas odpowiedzi pierwszego z protokołów

Konfiguracja	REST–Envoy	REST–Direct	Envoy–Direct	Rozstrz.
Echo, 200 rek., VU=10	$-0,9 \pm 0,9$	$1,1 \pm 0,7$	$2,0 \pm 0,3$	tak
Echo, 500 rek., VU=10	$24,5 \pm 1,0$	$25,8 \pm 1,6$	$1,2 \pm 0,9$	tak
Echo, 2000 rek., VU=10	$47,6 \pm 3,8$	$50,5 \pm 3,3$	$2,9 \pm 3,4$	tak
Echo, 500 rek., VU=20	$20,9 \pm 2,7$	$23,6 \pm 5,7$	$2,7 \pm 7,2$	tak
Products, PS=200, VU=10	$-1,4 \pm 3,8$	$1,4 \pm 2,5$	$2,7 \pm 2,4$	nie
Products, PS=500, VU=10	$23,4 \pm 2,4$	$24,9 \pm 1,6$	$1,5 \pm 1,4$	tak
Products, PS=1000, VU=10	$20,1 \pm 4,3$	$23,1 \pm 1,2$	$3,0 \pm 3,7$	tak
Products, PS=2000, VU=10	$43,3 \pm 4,9$	$44,0 \pm 3,5$	$0,8 \pm 2,2$	tak
Products, PS=500, VU=20	$23,2 \pm 1,4$	$27,4 \pm 1,5$	$4,2 \pm 1,8$	tak
Products, PS=1000, VU=20	$24,1 \pm 3,6$	$24,5 \pm 1,9$	$0,4 \pm 3,1$	tak
Orders, 10 poz., VU=10	$12,0 \pm 32,5$	$19,5 \pm 35,5$	$7,6 \pm 31,9$	nie
Orders, 50 poz., VU=10	$-2,4 \pm 3,1$	$7,4 \pm 25,4$	$9,8 \pm 23,8$	nie
Orders, 10 poz., VU=20	$-11,0 \pm 21,3$	$-17,1 \pm 28,9$	$-6,1 \pm 22,6$	nie
Orders, 50 poz., VU=20	$11,5 \pm 60,1$	$-47,6 \pm 76,0$	$-59,1 \pm 45,2$	nie
Kolumna <i>Rozstrz.</i> odnosi się do różnicy REST–Direct				

nica REST–Direct wynosi $1,4 \pm 2,5$ ms, a zatem nie jest rozstrzygnięta. W scenariuszu Echo przy tej samej liczbie rekordów różnica wynosi $1,1 \pm 0,7$ ms i pozostaje jednocześnie bez znaczenia praktycznego wobec opóźnienia obiegu pakietu wynoszącego 26,2 ms. Rozdzielenie istotności statystycznej od praktycznej jest w tym zakresie konieczne: wynik ten oznacza, że różnica istnieje i jest powtarzalna.

Po trzecie, różnica pomiędzy oboma wariantami gRPC–Web jest rozstrzygnięta jedynie w pięciu z dziesięciu konfiguracji odczytu, a jej wielkość mieści się w przedziale od $0,4 \pm 3,1$ do $4,2 \pm 1,8$ ms. Wielkość efektu jest zatem porównywalna z niepewnością jego oszacowania, co stanowi uzasadnienie wniosku o drugorzędnym znaczeniu wyboru pomiędzy wariantem bezpośrednim a wariantem z proxy.

Po czwarte, w scenariuszach zapisu żadna z różnic nie jest rozstrzygnięta. Przedziały są w tej grupie od kilku do kilkudziesięciu razy szersze niż w odczycie. Jedyne wyjątek dotyczy pary Envoy–Direct przy pięćdziesięciu pozycjach i dwudziestu klientach ($-59,1 \pm 45,2$ ms), lecz znak tej różnicy jest przeciwny niż w pozostałych komórkach tej grupy, a jej wartość wynika z jednego odstającego przebiegu. Obserwacji tej nie można zatem interpretować jako właściwości protokołu.

8.9 Weryfikacja hipotez badawczych

H1 (warianty gRPC–Web osiągają niższe opóźnienie niż REST, a przewaga rośnie z rozmiarem odpowiedzi): hipoteza potwierdzona z zastrzeżeniem dotyczącym charakteru zależności. Przewaga występuje i jest znaczna: 26–43% przy odpowiedziach od 500 rekordów. Zależność od rozmiaru odpowiedzi nie jest jednak

ciągła, jak zakładano, lecz skokowa: ujawnia się dopiero po przekroczeniu rozmiaru okna odbiorczego, a w zakresie do 200 rekordów pozostaje w granicach kilku procent. Poprawne sformułowanie hipotezy musi zatem odnosić się nie do rozmiaru odpowiedzi jako takiego, lecz do liczby okien niezbędnych do jej przesłania.

H2 (przy małych odpowiedziach różnice są nieistotne): hipoteza potwierdzona. Przy odpowiedziach do 200 rekordów różnice wynoszą od jednego do szesnastu procent, przy wartościach bezwzględnych od jednej do pięciu milisekund, wobec opóźnienia obiegu pakietu wynoszącego 26,2 ms. Samo opóźnienie propagacji stanowi w tym zakresie od około pięćdziesięciu siedmiu procent czasu odpowiedzi przy dwudziestu równoległych klientach i dwustu rekordach do siedemdziesięciu ośmiu procent przy dziesięciu klientach i dziesięciu rekordach. Właściwym wnioskiem jest zatem nie tyle brak różnicy, ile jej praktyczna nieistotność.

H3 (przewaga wynika z redukcji wolumenu danych, nie z wersji protokołu HTTP): hipoteza potwierdzona. Dekompozycja przedstawiona w sekcji 8.6 wykazała, że składnik serializacyjny odpowiada za około 95% obserwowanej przewagi, natomiast składnik obejmujący wersję protokołu HTTP oraz pominięcie serwera pośredniczącego, za nie więcej niż sześć procent. Wariant z proxy Envoy, korzystający z protokołu HTTP/1.1, dorównuje wariantowi bezpośredniemu, a nie ścieżce REST.

H4 (w operacjach zapisu różnice zanikają): hipoteza potwierdzona. Przy dziesięciu i pięćdziesięciu pozycjach zamówienia wszystkie warianty mieszczą się w przedziale 83,5–106,2 ms. Przyczyną jest dominacja stałego kosztu serwerowego oraz fakt, że żądania zapisu nie przekraczają rozmiaru okna odbiorczego, a zatem mechanizm dający przewagę w odczycie nie ma zastosowania.

H5 (wariant Direct osiąga niższe opóźnienie niż wariant z proxy Envoy): hipoteza potwierdzona, lecz o znaczeniu marginalnym. Wariant bezpośredni jest szybszy w każdej konfiguracji odczytu z ciepłą pamięcią podręczną oraz w każdej konfiguracji scenariusza Echo, jednak przewaga nie przekracza sześciu procent. W grupie scenariuszy z zimną pamięcią podręczną relacja ta nie zachodzi konsekwentnie co należy przypisać zmienności warstwy danych. Wybór pomiędzy oboma wariantami wdrożenia gRPC-Web ma znaczenie drugorzędne.

Podsumowanie

W ramach niniejszej pracy:

- ▶ zebrano i usystematyzowano wiedzę z zakresu architektury mikroserwisowej, mechanizmów komunikacji synchronicznej i asynchronicznej oraz wzorców projektowych dla systemów rozproszonych w ekosystemie .NET,
- ▶ dokonano szczegółowej analizy protokołu gRPC-Web i jego wariantów wdrożeniowych (proxy Envoy, bezpośrednia obsługa w oprogramowaniu pośredniczącym ASP.NET Core),
- ▶ zaprojektowano i zaimplementowano autorski system testowy składający się z dwóch mikroserwisów .NET 10 (ProductService, OrderService), infrastruktury wspierającej (PostgreSQL, Redis, Envoy Proxy) oraz warstwy obserwowalności (Prometheus, Grafana),
- ▶ zaimplementowano wzorzec Cache-Aside z wykorzystaniem Redis, a także skonfigurowano serwer Kestrel do równoległej obsługi trzech protokołów,
- ▶ opracowano metodykę pomiarową opartą na rzeczywistej przeglądarce internetowej, w której czas mierzony jest wewnątrz strony, od interakcji użytkownika do naniesienia odpowiedzi na drzewo dokumentu, co obejmuje pełną ścieżkę odczuwaną przez użytkownika aplikacji przeglądarkowej,
- ▶ przeprowadzono 39 konfiguracji pomiarowych w pięciu niezależnych powtórzeniach z rotowaną kolejnością protokołów, co dało 585 wykonanych testów i 171 tysięcy pomiarów, badając wpływ protokołu komunikacji, rozmiaru odpowiedzi, stanu pamięci podręcznej oraz liczby równoległych klientów na czas odpowiedzi systemu,
- ▶ poddano wyniki analizie statystycznej, wyznaczając przedziały ufności dla różnic sparowanych w obrębie przebiegu.

Główne wnioski z przeprowadzonych badań eksperymentalnych:

1. Warianty gRPC-Web skracają czas odpowiedzi o 26–43% względem REST, lecz wyłącznie przy nieskompresowanych odpowiedziach przekraczających

rozmiar okna odbiorczego protokołu TCP, czyli około 64 kilobajtów. Poniżej tego progu różnice nie przekraczają kilku procent i pozostają bez praktycznego znaczenia.

2. Zakres stosowalności powyższego wniosku ogranicza kompresja treści. Wykazano, że kompresja gzip redukuje wolumen dokumentu JSON dwunasto- do trzynastokrotnie, a wiadomości binarnej dziesięciokrotnie, przez co przewaga objętościowa formatu binarnego maleje z 33% do 15–18%, a wszystkie badane ładunki, niezależnie od formatu, mieszczą się po kompresji w jednym oknie odbiorczym. W konfiguracji z kompresją mechanizm odpowiadający za zmierzoną przewagę nie zostałby zatem uruchomiony w całym badanym zakresie rozmiarów odpowiedzi.
3. Zależność przewagi od rozmiaru odpowiedzi nie ma charakteru ciągłego, lecz realizuje się skokowo. Sformułowany model wyjaśnia ją liczbą wymian pakietów niezbędnych do przesłania odpowiedzi: transmisja wymaga tylu obiegów, ile okien odbiorczych zajmuje ładunek, a przewaga formatu binarnego polega na zmniejszeniu tej liczby. Przewidywania modelu zgadzają się z pomiarem w dziesięciu niezależnych konfiguracjach.
4. Około 95% obserwowanej przewagi wynika z formatu serializacji, a nie z zastosowanej wersji protokołu HTTP. Rozdzielenie obu czynników umożliwił wariant z proxy Envoy, który przenosi ładunek binarny, korzystając po stronie przeglądarki z protokołu HTTP/1.1, tak samo jak REST, i wynikami dorównuje wariantowi opartemu na HTTP/2, nie zaś ścieżce REST.
5. Serializacja Protocol Buffers redukuje wolumen przesyłanych danych o 32–43%. Wielkość ta nie zależy od warunków sieciowych, obciążenia ani od zastosowanego narzędzia pomiarowego. Jedynym czynnikiem, który ją zmienia, jest kompresja treści omówiona we wniosku drugim.
6. Przewaga protokołów binarnych skaluje się z opóźnieniem sieci, a nie z szybkością serwera, ponieważ wyraża się liczbą zaoszczędzonych obiegów pakietu. W komunikacji przez łącze rozległe o opóźnieniu 26 ms jest znacząca, natomiast w sieci lokalnej stałaby się pomijalna.
7. W operacjach zapisu wybór protokołu nie wpływa na czas odpowiedzi. Wszystkie badane warianty mieszczą się w przedziale 83–106 ms przy zmieniającym się pięciokrotnie rozmiarze żądania, ponieważ czas ten zdominowany jest przez stały koszt serwerowy rzędu 60–70 ms, obejmujący transakcję bazodanową.
8. Różnica pomiędzy wariantem gRPC-Web obsługiwanym bezpośrednio a wariantem z proxy Envoy nie przekracza sześciu procent. Wobec skali efektu

serializacyjnego wybór pomiędzy oboma wariantami wdrożenia ma znaczenie drugorzędne.

9. Zmienność pomiarów okazała się silnie zależna od udziału warstwy danych w czasie odpowiedzi: od poniżej jednego procenta w scenariuszach izolujących narzut protokołu do ponad pięćdziesięciu procent w scenariuszach wymuszających zapytanie do bazy oraz w operacjach zapisu. Wprowadzenie pamięci podręcznej obniża tę zmienność.
10. Ustalono granicę wiarygodności stanowiska pomiarowego. Przepustowość osiąga wartość graniczną pomiędzy dwudziestoma a trzydziestoma równoległymi klientami i powyżej niej przestaje rosnać, natomiast opóźnienie nadal narasta, ponieważ wszystkie trzy protokoły zatrzymują się na tej samej wartości granicznej mimo odmiennych ścieżek przetwarzania po stronie serwera, czynnik ograniczający zidentyfikowano po stronie klienta. Macierz badawczą ograniczono w konsekwencji do zakresu, w którym pomiar pozostaje wiarygodny.

Postawiony cel pracy uznano za osiągnięty: zaprojektowano i zrealizowano działający system mikroservisowy, przeprowadzono na nim zaplanowany zestaw badań oraz udzielono odpowiedzi na pytanie o relację wydajnościową badanych protokołów. Odpowiedź ta okazała się warunkowa, a sformułowany warunek, czyli rozmiar odpowiedzi w odniesieniu do okna odbiorczego protokołu TCP, jest wielkością mierzalną i możliwą do sprawdzenia w konkretnym zastosowaniu. Wszystkie pięć hipotez rozstrzygnięto, przy czym dwie z nich wymagały doprecyzowania sformułowania: hipoteza H1 w zakresie charakteru zależności od rozmiaru odpowiedzi, a hipoteza H5 w zakresie praktycznej istotności wykazanej różnicy.

Postawiona we wstępie teza znalazła w przeprowadzonych badaniach potwierdzenie. Przewaga wydajnościowa protokołów opartych na binarnej serializacji nie okazała się własnością bezwarunkową: ujawnia się wyłącznie wtedy, gdy mniejszy wolumen odpowiedzi zmniejsza liczbę wymian pakietów niezbędnych do jej przesłania, a w pozostałych badanych warunkach (przy małych ładunkach, w operacjach zapisu oraz, jak wskazuje oszacowanie objętościowe, przy włączonej kompresji treści) różnice pomiędzy protokołami pozostają praktycznie nieistotne.

Zaprojektowany i zrealizowany system ten charakteryzuje się następującymi cechami:

- ▶ równoległa obsługa trzech protokołów komunikacji w ramach jednej aplikacji klienckiej, umożliwiającą ich porównanie przy identycznej logice biznesowej, tych samych danych oraz niezmienionej ścieżce prezentacji,
- ▶ podejście Contract-First, w którym pliki `.proto` stanowią jedyne źródło prawdy, a kod serwera (C#) i klienta (TypeScript) jest z nich generowany,

- ▶ kompleksowa obserwowalność obejmująca metryki, ślady rozproszone oraz pulpity wizualizacyjne, umożliwiające korelację wyników eksperymentu z wewnętrznym stanem systemu.

Kierunki dalszego rozwoju pracy obejmują:

- ▶ rozdzielenie stanowiska pomiarowego na wiele maszyn klienckich, co pozwoliłoby przenieść granicę wiarygodności opisaną w ostatnim z powyższych wniosków i objąć pomiarem poziomy współbieżności rzędu setek równoległych klientów,
- ▶ powtórzenie eksperymentu przy różnych wartościach opóźnienia łącza, co umożliwiłoby empiryczną weryfikację przewidywanej proporcjonalności przewagi protokołów binarnych do opóźnienia sieci,
- ▶ powtórzenie macierzy z włączoną kompresją ciała odpowiedzi na wszystkich ścieżkach, co pozwoliłoby zweryfikować pomiarowo przedstawione oszacowanie objętościowe i ustalić, czy w takiej konfiguracji różnice pomiędzy protokołami pozostają wykrywalne,
- ▶ wdrożenie systemu na platformie Kubernetes (AKS) z automatycznym skalowaniem horyzontalnym i badanie wpływu liczby replik na wydajność.

Bibliografia

- [1] Niswar M., Safruddin R.A., Bustamin A., Aswad I., *Performance Evaluation of Microservices Communication with REST, GraphQL, and gRPC*, International Journal of Electronics and Telecommunications
- [2] Newman S., *Building Microservices. Designing Fine-Grained Systems*, wyd. 2, O'Reilly Media, 2021.
- [3] Fowler M., Lewis J., Microservices – a definition of this new architectural term, <https://martinfowler.com/articles/microservices.html>, stan na dzień: 23.08.2026
- [4] Richardson C., *Microservices Patterns. With Examples in Java*, Manning Publications, 2018.
- [5] Evans E., *Domain-Driven Design: Tackling Complexity in the Heart of Software*, Addison-Wesley Professional, 2003.
- [6] Microsoft Corporation, .NET documentation, <https://learn.microsoft.com/pl-pl/dotnet/>, stan na dzień: 23.08.2026
- [7] Microsoft Corporation, eShop – a .NET reference application implementing an e-commerce site, <https://github.com/dotnet/eShop>, stan na dzień: 23.06.2026
- [8] TechEmpower, TechEmpower Framework Benchmarks, runda 23 (luty 2025), <https://www.techempower.com/benchmarks/>, stan na dzień: 23.08.2026
- [9] Microsoft Corporation, .NET and .NET Core Support Policy, <https://dotnet.microsoft.com/platform/support/policy/dotnet-core>, stan na dzień: 23.08.2026
- [10] Microsoft Corporation, Native AOT deployment, <https://learn.microsoft.com/dotnet/core/deploying/native-aot/>, stan na dzień: 23.08.2026
- [11] OpenTelemetry Authors, OpenTelemetry Documentation, <https://opentelemetry.io/docs/>, stan na dzień: 23.08.2026
- [12] Fielding R., *Architectural Styles and the Design of Network-based Software Architectures*, Doctoral Dissertation, University of California, Irvine, 2000.

- [13] Fowler M., Richardson Maturity Model,
<https://martinfowler.com/articles/richardsonMaturityModel.html>, stan na dzień:
23.08.2026
- [14] Peon R., Ruellan H., HPACK: Header Compression for HTTP/2, RFC 7541,
<https://www.rfc-editor.org/rfc/rfc7541>, stan na dzień: 23.08.2026
- [15] gRPC Documentation, <https://grpc.io/docs/>, stan na dzień: 23.08.2026
- [16] Google Developers, Protocol Buffers Documentation, <https://protobuf.dev/>,
stan na dzień: 23.08.2026
- [17] gRPC-Web – gRPC for Web Clients, <https://grpc.io/docs/platforms/web/>, stan
na dzień: 23.08.2026
- [18] Envoy Proxy Documentation, <https://www.envoyproxy.io/docs/>, stan na dzień:
23.08.2026
- [19] gRPC-Web Wire Format (PROTOCOL-WEB),
<https://github.com/grpc/grpc/blob/master/doc/PROTOCOL-WEB.md>, stan na
dzień: 23.08.2026
- [20] gRPC-Web in ASP.NET Core gRPC apps, Microsoft Corporation,
<https://learn.microsoft.com/aspnet/core/grpc/grpcweb>, stan na dzień:
23.08.2026
- [21] Thomson M., Benfield C., HTTP/2, RFC 9113,
<https://www.rfc-editor.org/rfc/rfc9113>, stan na dzień: 23.08.2026
- [22] Google Developers, Protocol Buffers Reference Guides,
<https://protobuf.dev/reference/>, stan na dzień: 23.08.2026
- [23] Wiggins A., The Twelve-Factor App, <https://12factor.net/>, stan na dzień:
23.08.2026
- [24] Nygard M.T., *Release It! Design and Deploy Production-Ready Software*,
wyd. 2, Pragmatic Bookshelf, 2018.
- [25] Microsoft Corporation, APIs overview – Minimal APIs in ASP.NET Core,
<https://learn.microsoft.com/aspnet/core/fundamentals/minimal-apis/overview>,
stan na dzień: 23.08.2026
- [26] Microsoft Corporation, Cache-Aside pattern, Azure Architecture Center,
<https://learn.microsoft.com/azure/architecture/patterns/cache-aside>, stan na
dzień: 23.08.2026

- [27] Microsoft Corporation, Connection Resiliency – EF Core,
<https://learn.microsoft.com/ef/core/miscellaneous/connection-resiliency>, stan na dzień: 23.08.2026
- [28] Microsoft Corporation, Playwright Documentation,
<https://playwright.dev/docs/intro>, stan na dzień: 23.08.2026
- [29] Buf Technologies, Connect for Web Documentation,
<https://connectrpc.com/docs/web/getting-started/>, stan na dzień: 23.08.2026
- [30] Google LLC, Chrome DevTools Protocol,
<https://chromedevtools.github.io/devtools-protocol/>, stan na dzień: 23.08.2026
- [31] Eddy W., Transmission Control Protocol (TCP), RFC 9293,
<https://www.rfc-editor.org/rfc/rfc9293>, stan na dzień: 23.08.2026
- [32] Jain R., *The Art of Computer Systems Performance Analysis: Techniques for Experimental Design, Measurement, Simulation, and Modeling*, John Wiley & Sons, 1991.

Spis rysunków

6.1	Pulpit Grafany – liczba żądań na sekundę oraz percentyle czasu obsługi żądania po stronie usług <code>ProductService</code> i <code>OrderService</code>	22
6.2	Pulpit Grafany – liczba żądań w podziale na trasy oraz metryki środowiska uruchomieniowego .NET: wolumen alokacji i częstość odświeżania pamięci	23
7.1	Konsola Hetzner Cloud – parametry serwera, na którym wdrożono system testowany	32
7.2	Wykorzystanie procesora oraz przepustowość dysku serwera w trakcie pracy systemu pod obciążeniem (pulpit konsoli Hetzner Cloud) .	33
8.1	Mediana opóźnień w scenariuszach Echo względem liczby rekordów w odpowiedzi	41
8.2	Mediana opóźnień w scenariuszach Products z ciepłą pamięcią podręczną, dla dziesięciu i dwudziestu równoległych klientów; słupki błędów odpowiadają 95% przedziałowi ufności wartości centralnej. . .	43
8.3	Mediana opóźnień w scenariuszach Products z zimną pamięcią podręczną; słupki błędów odpowiadają 95% przedziałowi ufności wartości centralnej	44
8.4	Mediana opóźnień w scenariuszach Orders względem liczby pozycji zamówienia; słupki błędów odpowiadają 95% przedziałowi ufności wartości centralnej	45
8.5	Udział składnika serializacyjnego oraz transportowego w skróceniu czasu odpowiedzi względem REST; wartości procentowe odniesiono do mediany opóźnień REST	46
8.6	Opóźnienie i przepustowość względem liczby równoległych klientów; szary pas oznacza wspólny pułap przepustowości, różowy – położenie punktu przegięcia	48

Spis tabel

2.1	Porównanie architektury monolitycznej i mikroserwisowej; opracowanie własne na podstawie [2, 4]	7
4.1	Porównanie natywnego gRPC, gRPC-Web oraz REST w kontekście komunikacji frontend-backend	14
6.1	Limity zasobów kontenerów w konfiguracji wdrożeniowej systemu autorskiego	21
7.1	Wymiary macierzy badawczej	31
7.2	Zmierzona charakterystyka łącza klient–serwer	34
7.3	Zweryfikowana warstwa transportowa poszczególnych ścieżek komunikacji	34
8.1	Zmierzony rozmiar odpowiedzi [B] i redukcja uzyskana serializacją binarną	38
8.2	Rozmiar ładunku scenariusza Echo bez kompresji i po kompresji gzip [B] oraz wynikająca z niego liczba okien odbiorczych	38
8.3	Weryfikacja modelu – przewidywana i zmierzona liczba dodatkowych obiegów pakietu	40
8.4	Mediana opóźnienia w scenariuszach Echo [ms]; w nawiasach współczynnik zmienności median pięciu przebiegów	41
8.5	Mediana opóźnienia w scenariuszach Products, ciepła pamięć podręczna [ms]; w nawiasach współczynnik zmienności median pięciu przebiegów	42
8.6	Mediana opóźnienia w scenariuszach Products, zimna pamięć podręczna [ms]; w nawiasach współczynnik zmienności.	43
8.7	Mediana opóźnienia w scenariuszach Orders [ms]; w nawiasach współczynnik zmienności	45
8.8	Dekompozycja przewagi na składnik serializacyjny i transportowy [ms]	46
8.9	Skalowanie z liczbą równoległych klientów – mediana opóźnienia [ms] i przepustowość [operacji/s]	47

8.10 Współczynnik zmienności median pięciu przebiegów, w podziale na grupy scenariuszy	48
8.11 Przedziały ufności 95% dla wartości centralnej opóźnienia [ms]; $k = 5$ przebiegów, $t = 2,776$	49
8.12 Przedziały ufności 95% dla różnic sparowanych w obrębie przebiegu [ms]; wartość dodatnia oznacza dłuższy czas odpowiedzi pierwszego z protokołów	50

Spis listingów

3.1	Definicja punktu końcowego REST z wykorzystaniem Minimal API w .NET 10	10
3.2	Definicja serwisu gRPC w formacie Protocol Buffers	11
4.1	Generowanie kodu klienckiego dla Connect RPC	16
7.1	Punkt końcowy Echo izolujący narzut protokołu od warstwy danych .	27

Streszczenie

Praca pt. „Architektura mikroserwisów i rozwiązania chmurowe w ekosystemie .NET” poświęcona jest projektowaniu, implementacji oraz empirycznej analizie wydajności systemu rozproszonego zbudowanego w oparciu o platformę .NET 10. W ostatnim czasie obserwuje się intensywny rozwój protokołu gRPC jako alternatywy dla powszechnie stosowanego REST w komunikacji między mikroserwisami. Jednocześnie środowisko przeglądarek internetowych wymaga stosowania wariantu *gRPC-Web*, którego wydajność w komunikacji klient–backend pozostaje słabo zbadana empirycznie. W rozważanej pracy podjęto zatem próbę wypełnienia tej luki badawczej. W szczególności zebrano wiadomości z zakresu architektury mikroserwisów, mechanizmów komunikacji synchronicznej i asynchronicznej oraz wzorców projektowych w ekosystemie .NET, porównano trzy warianty komunikacji dostępne dla aplikacji przeglądarkowej: REST (HTTP/1.1 z serializacją JSON), gRPC-Web przez proxy Envoy oraz gRPC-Web obsługiwany bezpośrednio w ASP.NET Core, zrealizowano system testowy złożony z dwóch mikroserwisów (*ProductService* i *OrderService*), wdrożony na serwerze chmury Hetzner, a także opracowano metodykę pomiarową opartą na rzeczywistej przeglądarce internetowej, w której czas mierzony jest od interakcji użytkownika do naniesienia odpowiedzi na drzewo dokumentu. Przeprowadzono 39 konfiguracji pomiarowych w pięciu niezależnych powtórzeniach z rotowaną kolejnością protokołów, co dało 585 wykonanych testów i 171 tysięcy pomiarów, przy rozmiarach ładunku od 10 do 2000 rekordów oraz scenariuszach obejmujących izolowany narzut protokołu, odczyt katalogu i zapis zamówienia. Zaprojektowany i zaimplementowany system charakteryzuje się następującymi cechami: podejściem *contract-first* opartym na *Protocol Buffers* zapewniającym silną typizację w całym stosie technologicznym oraz kompleksową obserwowalnością zgodną ze standardem OpenTelemetry, obejmującą metryki eksportowane do Prometheusa i wizualizowane w Grafanie. Przeprowadzone badania wykazały, że warianty gRPC-Web skracają czas odpowiedzi o 26–43% względem REST, lecz wyłącznie przy nieskompresowanych odpowiedziach przekraczających rozmiar okna odbiorczego protokołu TCP; przy typowych ładunkach interfejsu użytkownika oraz w operacjach zapisu różnice pozostają nieistotne. Wykazano ponadto, że kompresja treści redukuje wolumen dokumentu JSON dwunasto- do trzynastokrotnie i sprowadza wszystkie badane

ładunki poniżej rozmiaru jednego okna odbiorczego, co wyznacza granicę stosowalności powyższego wniosku. Sformułowano model wyjaśniający tę zależność liczbą wymian pakietów wynikającą z wolumenu odpowiedzi, którego przewidywania zgadzają się z pomiarem z dokładnością do 0,2 obiegu pakietu. Wykazano ponadto, że około 95% obserwowanej przewagi wynika z binarnej serializacji redukującej wolumen danych o 42–43%, a nie z zastosowanej wersji protokołu HTTP, oraz że korzyść ta skaluje się z opóźnieniem sieci, nie z szybkością serwera.

Summary

The thesis entitled “*Microservices Architecture and Cloud Solutions in the .NET Ecosystem*” is devoted to the design, implementation, and empirical performance analysis of a distributed system built on the .NET 10 platform. Recently, rapid growth and adoption of the gRPC protocol have been observed as an alternative to the widely used REST for inter-microservice communication. At the same time, the web browser environment necessitates the use of the *gRPC-Web* variant, whose performance in client–backend communication remains insufficiently investigated empirically. This study therefore aims to address and fill this research gap. In particular, the thesis synthesizes knowledge in microservices architecture, synchronous and asynchronous communication mechanisms, and design patterns within the .NET ecosystem; compares three communication variants available to web browser applications: REST (HTTP/1.1 with JSON serialization), gRPC-Web via an Envoy proxy, and gRPC-Web natively hosted in ASP.NET Core; implements a benchmark test-bed consisting of two microservices (*ProductService* and *OrderService*) deployed on a Hetzner Cloud server; and establishes a measurement methodology based on a real web browser, where end-to-end latency is measured from the initial user interaction to the rendering of the response into the Document Object Model (DOM) tree. A total of 39 measurement configurations were executed across five independent repetitions with rotated protocol ordering, yielding 585 test runs and 171 thousand individual measurements, spanning payload sizes from 10 to 2000 records across scenarios covering isolated protocol overhead, catalog read, and order placement. The designed and implemented system is characterized by a *contract-first* approach based on *Protocol Buffers* providing strong typing across the entire technology stack and comprehensive observability compliant with the OpenTelemetry standard, encompassing metrics exported to Prometheus and visualized in Grafana. The empirical evaluation revealed that gRPC-Web variants reduce response times by 26–43% compared to REST, but exclusively for uncompressed responses exceeding the initial TCP receive window size; for typical user interface payloads and write operations, the differences remain negligible. Furthermore, it was demonstrated that response compression reduces JSON document size by a factor of 12–13, bringing all evaluated payloads below the threshold of a single receive window, thereby defining the boundary of practical applicability for the aforementioned perfor-

mance advantage. A model accounting for this relationship based on the number of network round-trips dictated by payload volume was formulated, with predictions aligning with empirical measurements within 0.2 packet round-trips. In addition, it was established that approximately 95% of the observed performance gain is attributable to binary serialization reducing data volume by 42–43%, rather than the underlying HTTP transport version, and that this benefit scales primarily with network latency rather than server compute capacity.

Słowa kluczowe

mikroserwisy;
gRPC-Web;
REST API;
Protocol Buffers;
ASP.NET Core;
Envoy Proxy;
testy wydajnościowe;
architektura rozproszona;
.NET 10;
HTTP/2;

Imię i nazwisko: Mariusz Trzeciak

Nr albumu: 133583

Kierunek: Informatyka

Wydział: Informatyki i Sztucznej Inteligencji

Oświadczenie autora pracy dyplomowej*

Oświadczam pod rygorem odpowiedzialności karnej, że złożona przeze mnie praca dyplomowa pt. „*Architektura mikroserwisów i rozwiązania chmurowe w ekosystemie .NET*” jest moim samodzielnym opracowaniem i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Jednocześnie oświadczam, że moja praca (w całości ani we fragmentach) nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w Politechnice Częstochowskiej.

Wyrażam/~~nie wyrażam~~** zgodę/zgody na nieodpłatne wykorzystanie przez Politechnikę Częstochowską całości lub fragmentów wyżej wymienionej pracy w publikacjach Politechniki Częstochowskiej.

.....
podpis studenta

*W przypadku zbiorowej pracy dyplomowej, dołącza się oświadczenia każdego ze współautorów pracy dyplomowej.

*Niepotrzebne skreślić.